



Mahidol
University



รายงาน

การพัฒนาเครื่องมือวิเคราะห์อารมณ์ผู้ป่วยด้วยปัญญาประดิษฐ์เพื่อสนับสนุน

การตัดสินใจร่วมในงานทันตกรรม

ผู้จัดทำ

นางสาวเตชินี รัตน์วิมล

รหัสนักศึกษา 6687003

นายภาวิษฐ์ พันธุ์จันทร์อุไร

รหัสนักศึกษา 6687040

นางสาววรรณลิดา ศุภศรอิสระ

รหัสนักศึกษา 6687070

เสนอ

อาจารย์ ดร.กนกศักดิ์ วัฒนะโชติ

รายงานนี้ เป็นส่วนหนึ่งของรายวิชา ITDS346 Practical Data Science

มหาวิทยาลัยมหิดล ภาคการศึกษา 2/2568

คำนำ

ในปัจจุบันเทคโนโลยีปัญญาประดิษฐ์ (Artificial Intelligence: AI) โดยเฉพาะด้านการประมวลผลภาษาธรรมชาติ (Natural Language Processing: NLP) ได้เข้ามามีบทบาทสำคัญในการวิเคราะห์และตีความข้อความของมนุษย์อย่างแพร่หลาย หนึ่งในงานที่ได้รับความสนใจคือการวิเคราะห์อารมณ์จากข้อความ (Sentiment Analysis) ซึ่งสามารถนำไปประยุกต์ใช้ได้หลากหลายด้าน รวมถึงด้านการแพทย์และทันตกรรม ที่การสื่อสารระหว่างผู้ป่วยและบุคลากรทางการแพทย์มีความสำคัญอย่างยิ่งต่อการตัดสินใจและประสิทธิภาพในการรักษา

โครงการนี้จัดทำขึ้นเพื่อพัฒนาระบบวิเคราะห์อารมณ์จากข้อความสนทนาในบริบททางทันตกรรม โดยนำเทคนิค Machine Learning และ Deep Learning มาประยุกต์ใช้ร่วมกับแนวทาง Hybrid Model ที่ผสมผสานการทำงานกับ Large Language Model (LLM) เพื่อเพิ่มประสิทธิภาพในการจำแนกอารมณ์ของข้อความ โดยมุ่งเน้นให้ระบบสามารถจัดการกับข้อความที่มีความกำกวม และสะท้อนอารมณ์ของผู้ป่วยได้อย่างถูกต้องมากยิ่งขึ้น ซึ่งจะช่วยสนับสนุนการสื่อสารและการตัดสินใจในกระบวนการรักษา

คณะผู้จัดทำหวังเป็นอย่างยิ่งว่าโครงการฉบับนี้จะเป็นประโยชน์ต่อผู้ที่สนใจศึกษาเกี่ยวกับการประยุกต์ใช้เทคโนโลยี AI ในงานด้านการวิเคราะห์ข้อความ รวมถึงสามารถนำไปต่อยอดในงานวิจัยหรือการพัฒนาระบบในบริบททางการแพทย์และทันตกรรมในอนาคตได้ หากมีข้อผิดพลาดประการใด คณะผู้จัดทำขออภัยไว้ ณ ที่นี้ และยินดีน้อมรับข้อเสนอแนะเพื่อนำไปปรับปรุงในโอกาสต่อไป

คณะผู้จัดทำ

สารบัญ

คำนำ.....	ก
สารบัญ.....	ข
สารบัญรูปภาพ.....	ฉ
สารบัญตาราง.....	ช
บทที่ 1 บทนำ.....	1
1.1 ความเป็นมาและความสำคัญของปัญหา	1
1.2 วัตถุประสงค์ของโครงการ.....	2
1.3 ขอบเขตของโครงการ.....	2
1.4 เครื่องมือที่ใช้	3
1.5 ประโยชน์ที่คาดว่าจะได้รับ	4
บทที่ 2 ทฤษฎีและงานวิจัยที่เกี่ยวข้อง.....	5
2.1 การเตรียมข้อมูลและการประมวลผลข้อความ	5
2.1.1 การเตรียมข้อมูล.....	5
2.1.2 การแบ่งชุดข้อมูล.....	5
2.1.3 การแทนข้อความเชิงตัวเลขด้วย TF-IDF	6
2.1.4 การแทนข้อความด้วย Tokenizer และ Padding สำหรับ Deep Learning.....	6
2.2 โมเดลและเทคนิคที่ใช้ในงานวิจัย	7
2.2.1 การเรียนรู้แบบมีผู้สอน	7
2.2.2 โมเดล Machine Learning สำหรับการจำแนกข้อความ	7
2.2.3 โมเดล Bidirectional LSTM.....	10
2.2.4 สถาปัตยกรรม Transformer และกลไก Attention	10
2.2.5 Large Language Models และการเรียนรู้แบบ Few-Shot.....	11
2.2.6 โมเดลแบบผสมผสาน (Hybrid Model)	12

2.2.7	ความสอดคล้องของโมเดล LLM ที่ใช้ในโครงการงาน	12
2.2.8	การประเมินผลโมเดล	13
2.3	งานวิจัยที่เกี่ยวข้อง	14
2.3.1	งานวิจัยด้าน Machine Learning	14
2.3.2	งานวิจัยด้าน Deep Learning	15
2.3.3	งานวิจัยด้าน Transformer และ Large Language Models.....	15
2.3.4	งานวิจัยด้าน Hybrid Model.....	15
บทที่ 3	วิธีการดำเนินโครงการงาน	17
3.1	ขั้นตอนการดำเนินงาน.....	17
3.2	การเตรียมข้อมูล (DATA PREPROCESSING).....	20
3.3	การพัฒนาโมเดล MACHINE LEARNING	24
3.3.1	การเตรียมข้อมูลสำหรับโมเดล (Data Preparation for Modeling)	24
3.3.2	การแปลงข้อความเป็นตัวเลข (Feature Extraction).....	24
3.3.3	โมเดลที่ใช้ (Model Selection).....	25
3.3.4	การฝึกโมเดล (Model Training)	26
3.3.5	การประเมินผลโมเดล (Model Evaluation).....	26
3.3.6	การบันทึกผลลัพธ์ (Result Saving).....	26
3.3.7	การจัดการปัญหา Class Imbalance	27
3.4	การพัฒนาโมเดล DEEP LEARNING	27
3.4.1	โครงสร้างโมเดล (Model Architecture).....	27
3.4.2	การกำหนดพารามิเตอร์ (Hyperparameters)	28
3.4.3	การฝึกโมเดล (Model Training)	28
3.4.4	การประเมินผลโมเดล (Model Evaluation).....	29
3.4.5	การจัดการปัญหา Class Imbalance และ Overfitting.....	29
3.5	การพัฒนาโมเดล HYBRID (MACHINE LEARNING / DEEP LEARNING ร่วมกับ LLM).....	30
3.5.1	แนวคิดและสถาปัตยกรรมแบบไฮบริด (Hybrid Architecture).....	30

3.5.2	กลไกการประเมินค่าความเชื่อมั่น (Confidence Threshold Mechanism)	31
3.5.3	การสร้างระบบธนาคารตัวอย่าง (Few-shot Bank Construction)	32
3.5.4	การออกแบบวิศวกรรมคำสั่ง (Hybrid Prompt Engineering)	33
3.6	ขั้นตอนการไหลของข้อมูลและอัลกอริทึม (DATA WORKFLOW & ALGORITHM)	34
3.7	การประเมินและเปรียบเทียบประสิทธิภาพ	35
บทที่ 4	ผลการดำเนินโครงการ	36
4.1	ผลลัพธ์ของ MACHINE LEARNING	36
4.1.1	การวิเคราะห์แนวโน้มการเรียนรู้ของโมเดล	36
4.1.2	ผลการประเมินประสิทธิภาพโดยรวม	39
4.1.3	การวิเคราะห์ผลในระดับรายคลาส	40
4.1.4	การวิเคราะห์ผลเชิงภาพ	42
4.2	ผลลัพธ์ของ DEEP LEARNING	43
4.2.1	การวิเคราะห์แนวโน้มการเรียนรู้ของโมเดล	43
4.2.2	ผลการประเมินประสิทธิภาพโดยรวม	44
4.2.3	การวิเคราะห์ผลในระดับรายคลาส	44
4.2.4	การวิเคราะห์ผลเชิงภาพ	45
4.3	ผลลัพธ์ของ HYBRID MODEL	45
4.3.1	ผลการประเมินประสิทธิภาพโดยรวมของ Llama3.1:8b	46
4.3.2	ผลการประเมินประสิทธิภาพโดยรวม DeepSeek-R1:8B	52
4.3.3	ผลการประเมินประสิทธิภาพโดยรวม Qwen 2.5:7B-Instruct	58
4.4	การเปรียบเทียบผล	64
4.4.1	การเปรียบเทียบโมเดลพื้นฐาน	64
4.4.2	การเปรียบเทียบ Hybrid Model ที่ใช้ Llama 3.1:8B	65
4.4.3	การเปรียบเทียบ Hybrid Model ที่ใช้ DeepSeek-R1:8B	65
4.4.4	การเปรียบเทียบ Hybrid Model ที่ใช้ Qwen 2.5:7B-Instruct	66
4.4.5	การเปรียบเทียบโมเดลที่ดีที่สุดในแต่ละกลุ่ม	66

4.4.6	สรุปผลการเปรียบเทียบ	67
4.5	CONFUSION MATRIX	67
4.5.1	ผลการวิเคราะห์ Confusion Matrix ของโมเดล Machine Learning และ Deep Learning 68	
4.5.2	ผลการวิเคราะห์ Confusion Matrix ของโมเดลที่ใช้ Llama3.1:8b	73
4.5.3	ผลการวิเคราะห์ Confusion Matrix ของโมเดลที่ใช้ DeepSeek-R1:8B	78
4.5.4	ผลการวิเคราะห์ Confusion Matrix ของโมเดลที่ใช้ Qwen 2.5:7B-Instruct.....	83
4.5.5	สรุปผล Confusion Matrix ของโมเดลทั้งหมด	88
บทที่ 5	สรุปผลและข้อเสนอแนะ	89
5.1	สรุปผลโครงงาน.....	89
5.2	ปัญหาที่พบ	90
5.3	ข้อเสนอแนะ	91
บรรณานุกรม.....		93

สารบัญรูปภาพ

รูปที่ 4.1-1 แนวโน้มค่า Loss และ Accuracy ของโมเดล Naive Bayes.....	36
รูปที่ 4.1-2 แนวโน้มค่า Loss และ Accuracy ของโมเดล Logistic Regression	37
รูปที่ 4.1-3 แนวโน้มค่า Loss และ Accuracy ของโมเดล Random Forest	37
รูปที่ 4.1-4 แนวโน้มค่า Loss และ Accuracy ของโมเดล Support Vector Machine (SVM)	38
รูปที่ 4.1-5 จำนวนการทำนายที่ถูกต้องในแต่ละคลาสของโมเดล Machine Learning	42
รูปที่ 4.2-1 แนวโน้มค่า Loss และ Accuracy ของโมเดล BiLSTM	43
รูปที่ 4.2-2 จำนวนการทำนายที่ถูกต้องในแต่ละคลาสของโมเดล Deep Learning	45
รูปที่ 4.3-1 แสดงจำนวนการทำนายถูกของแต่ละโมเดล Hybrid (Machine Learning ร่วมกับ Llama 3.1:8B) 50	
รูปที่ 4.3-2 จำนวนการทำนายถูกในแต่ละคลาสของโมเดล Hybrid (Deep Learning (BiLSTM)).....	51
รูปที่ 4.3-3 แสดงจำนวนการทำนายถูกของแต่ละโมเดล Hybrid (Machine Learning DeepSeek-R1:8B).....	56
รูปที่ 4.3-4 จำนวนการทำนายถูกในแต่ละคลาสของโมเดล Hybrid (Deep Learning (BiLSTM) ร่วมกับ DeepSeek-R1:8B).....	57
รูปที่ 4.3-5 แสดงจำนวนการทำนายถูกของแต่ละโมเดล Hybrid (Machine Learning Qwen 2.5:7B-Instruct)	62
รูปที่ 4.3-6 จำนวนการทำนายถูกในแต่ละคลาสของโมเดล Hybrid (Deep Learning (BiLSTM) ร่วมกับ Qwen 2.5:7B-Instruct).....	63
รูปที่ 4.5-1 Confusion Matrix ของโมเดล Naive Bayes.....	68
รูปที่ 4.5-2 Confusion Matrix ของโมเดล Logistic Regression.....	69
รูปที่ 4.5-3 Confusion Matrix ของโมเดล Random Forest.....	70
รูปที่ 4.5-4 Confusion Matrix ของโมเดล Support Vector Machine (SVM).....	71
รูปที่ 4.5-5 Confusion Matrix ของโมเดล Deep Learning (BiLSTM)	72
รูปที่ 4.5-6 Confusion Matrix ของโมเดล Naive Bayes ร่วมกับ Llama3.1:8b	73
รูปที่ 4.5-7 Confusion Matrix ของโมเดล Logistic Regression ร่วมกับ Llama3.1:8b.....	74
รูปที่ 4.5-8 Confusion Matrix ของโมเดล Random Forest ร่วมกับ Llama3.1:8b	75
รูปที่ 4.5-9 Confusion Matrix ของโมเดล Support Vector Machine ร่วมกับ Llama3.1:8b.....	76

รูปที่ 4.5-10 Confusion Matrix ของโมเดล Deep Learning (BiLSTM) ร่วมกับ Llama 3.1:8b	77
รูปที่ 4.5-11 Confusion Matrix ของโมเดล Naive Bayes ร่วมกับ DeepSeek R1	78
รูปที่ 4.5-12 Confusion Matrix ของโมเดล Logistic Regression ร่วมกับ DeepSeek-R1:8B	79
รูปที่ 4.5-13 Confusion Matrix ของโมเดล Random Forest ร่วมกับ DeepSeek-R1:8B	80
รูปที่ 4.5-14 Confusion Matrix ของโมเดล Support Vector Machine ร่วมกับ DeepSeek-R1:8B.....	81
รูปที่ 4.5-15 Confusion Matrix ของโมเดล Deep Learning (BiLSTM) ร่วมกับ DeepSeek-R1:8B	82
รูปที่ 4.5-16 Confusion Matrix ของโมเดล Naive Bayes ร่วมกับ Qwen 2.5:7B-Instruct	83
รูปที่ 4.5-17 Confusion Matrix ของโมเดล Logistic Regression ร่วมกับ Qwen 2.5:7B-Instruct	84
รูปที่ 4.5-18 Confusion Matrix ของโมเดล Random Forest ร่วมกับ Qwen 2.5:7B-Instruct	85
รูปที่ 4.5-19 Confusion Matrix ของโมเดล Support Vector Machine ร่วมกับ Qwen 2.5:7B-Instruct.....	86
รูปที่ 4.5-20 Confusion Matrix ของโมเดล Deep Learning (BiLSTM) ร่วมกับ DeepSeek-R1:8B	87

สารบัญตาราง

ตารางที่ 4.1-1 ผลการประเมินประสิทธิภาพของโมเดล Machine Learning (Test Set)	39
ตารางที่ 4.1-2 ผลการประเมินในระดับรายการของโมเดล Naive Bayes (Test Set)	40
ตารางที่ 4.1-3 ผลการประเมินในระดับรายการของโมเดล Logistic Regression (Test Set)	40
ตารางที่ 4.1-4 ผลการประเมินในระดับรายการของโมเดล Random Forest (Test Set)	41
ตารางที่ 4.1-5 ผลการประเมินในระดับรายการของโมเดล Support Vector Machine (SVM) (Test Set)	41
ตารางที่ 4.2-1 ผลการประเมินประสิทธิภาพของโมเดล Deep Learning (Test Set)	44
ตารางที่ 4.2-2 ตารางที่ 4.x ผลการประเมินในระดับรายการของโมเดล Deep Learning (Test Set)	44
ตารางที่ 4.3-1 ผลการประเมินประสิทธิภาพของ Hybrid Model (Llama 3.1:8B) (Test Set)	46
ตารางที่ 4.3-2 ผลการประเมินในระดับรายการของโมเดล Naive Bayes + Llama 3.1:8B (Test Set)	47
ตารางที่ 4.3-3 ผลการประเมินในระดับรายการของโมเดล Logistic Regression + Llama 3.1:8B (Test Set)	47
ตารางที่ 4.3-4 ผลการประเมินในระดับรายการของโมเดล Random Forest + Llama 3.1:8B (Test Set)	48
ตารางที่ 4.3-5 ผลการประเมินในระดับรายการของโมเดล Support Vector Machine + Llama 3.1:8B (Test Set)	49
ตารางที่ 4.3-6 ผลการประเมินในระดับรายการของโมเดล BiLSTM + Llama 3.1:8B	49
ตารางที่ 4.3-7 ผลการประเมินประสิทธิภาพของ Hybrid Model (DeepSeek-R1:8B) (Test Set)	52
ตารางที่ 4.3-8 ผลการประเมินในระดับรายการของโมเดล Naive Bayes + DeepSeek-R1:8B (Test Set)	53
ตารางที่ 4.3-9 ผลการประเมินในระดับรายการของโมเดล Logistic Regression + DeepSeek-R1:8B (Test Set)	53
ตารางที่ 4.3-10 ผลการประเมินในระดับรายการของโมเดล Random Forest + DeepSeek-R1:8B (Test Set)	54
ตารางที่ 4.3-11 ผลการประเมินในระดับรายการของโมเดล Support Vector Machine + DeepSeek-R1:8B (Test Set)	54
ตารางที่ 4.3-12 ผลการประเมินประสิทธิภาพของ Hybrid Model (Qwen 2.5:7B-Instruct) (Test Set)	58

ตารางที่ 4.3-13 ผลการประเมินในระดับรายคลาสของโมเดล Naive Bayes + Qwen 2.5:7B-Instruct (Test Set).....	59
ตารางที่ 4.3-14 ผลการประเมินในระดับรายคลาสของโมเดล Logistic Regression + Qwen 2.5:7B-Instruct (Test Set).....	59
ตารางที่ 4.3-15 ผลการประเมินในระดับรายคลาสของโมเดล Support Vector Machine + Qwen 2.5:7B-Instruct (Test Set).....	60
ตารางที่ 4.3-16 ผลการประเมินในระดับรายคลาสของโมเดล BiLSTM + Qwen 2.5:7B-Instruct (Test Set)...	61
ตารางที่ 4.4-1 การเปรียบเทียบประสิทธิภาพของโมเดลพื้นฐาน.....	64
ตารางที่ 4.4-2 การเปรียบเทียบประสิทธิภาพของ Hybrid Model ที่ใช้ Llama 3.1:8B.....	65
ตารางที่ 4.4-3 การเปรียบเทียบประสิทธิภาพของ Hybrid Model ที่ใช้ DeepSeek-R1:8B.....	65
ตารางที่ 4.4-4 การเปรียบเทียบประสิทธิภาพของ Hybrid Model ที่ใช้ Qwen 2.5:7B-Instruct	66
ตารางที่ 4.4-5 การเปรียบเทียบโมเดลที่มีประสิทธิภาพดีที่สุดในแต่ละกลุ่ม	66

บทที่ 1

บทนำ

1.1 ความเป็นมาและความสำคัญของปัญหา

ในปัจจุบันเทคโนโลยีปัญญาประดิษฐ์ (Artificial Intelligence: AI) ได้เข้ามามีบทบาทในหลายด้านอย่างต่อเนื่อง โดยเฉพาะด้านการประมวลผลภาษาธรรมชาติ (Natural Language Processing: NLP) ซึ่งช่วยให้คอมพิวเตอร์สามารถเข้าใจ วิเคราะห์ และตีความภาษามนุษย์ได้ เทคโนโลยีนี้สามารถนำมาใช้ในการวิเคราะห์ข้อความ แยกประเภทข้อมูล รวมถึงตรวจจับอารมณ์หรือความคิดเห็นที่แฝงอยู่ในภาษา นอกจากนี้ความก้าวหน้าของ Large Language Models และ Generative AI ยังทำให้ระบบสามารถเข้าใจบริบทของข้อความได้ดีขึ้น และเริ่มถูกนำไปใช้ในงานด้านการแพทย์ เช่น การให้ข้อมูล การช่วยสื่อสาร และการสนับสนุนการตัดสินใจ

ในบริบทของการสื่อสารระหว่างทันตแพทย์กับผู้ป่วย อารมณ์ของผู้ป่วย เช่น ความกังวล ความกลัว ความสับสน หรือความเชื่อมั่น เป็นปัจจัยที่มีผลต่อการตัดสินใจและความเข้าใจในการรักษา อย่างไรก็ตามอารมณ์เหล่านี้มักแสดงออกผ่านข้อความหรือคำพูดในลักษณะที่ไม่ตรงไปตรงมา ทำให้การวิเคราะห์ด้วยมนุษย์เพียงอย่างเดียวอาจใช้เวลาและอาจเกิดความคลาดเคลื่อนได้ งานวิจัยที่เกี่ยวข้องจึงนำการวิเคราะห์อารมณ์จากข้อความ (sentiment analysis) มาใช้เพื่อช่วยตรวจจับความรู้สึกและเจตนาของผู้พูด แต่ในบางกรณีข้อความอาจมีความกำกวมหรือซับซ้อน ซึ่งทำให้การวิเคราะห์ด้วยโมเดลเพียงอย่างเดียวอาจยังไม่เพียงพอ

ดังนั้น โครงการนี้จึงมีแนวคิดในการพัฒนาระบบวิเคราะห์อารมณ์จากข้อความสนทนา โดยใช้โมเดล Machine Learning และ Deep Learning เป็นตัวหลักในการจำแนกอารมณ์ และนำ Large Language Model เข้ามาช่วยในลักษณะ Hybrid เพื่อใช้ในการตีความข้อความเพิ่มเติมในกรณีที่ข้อความมีความซับซ้อนหรือไม่ชัดเจน แนวทางนี้มุ่งเน้นการศึกษาและเปรียบเทียบผลลัพธ์ของแต่ละวิธี เพื่อดูว่าสามารถช่วยให้การวิเคราะห์อารมณ์มีความสอดคล้องกับบริบทของข้อความมากขึ้นหรือไม่ และสามารถนำไปเป็นแนวทางในการพัฒนาระบบที่เกี่ยวข้องกับการสื่อสารในอนาคตได้

1.2 วัตถุประสงค์ของโครงการ

- 1) เพื่อศึกษาการวิเคราะห์อารมณ์จากข้อความสนทนาโดยใช้เทคนิค Machine Learning และ Deep Learning
- 2) เพื่อพัฒนาโมเดลสำหรับจำแนกอารมณ์จากข้อความสนทนาในบริบททางทันตกรรม
- 3) เพื่อเปรียบเทียบประสิทธิภาพของโมเดล Machine Learning, Deep Learning และแนวทาง Hybrid ที่ใช้ Artificial Intelligence หรือ Large Language Model ร่วมด้วย
- 4) เพื่อศึกษาว่าแนวทาง Hybrid สามารถช่วยปรับปรุงความถูกต้องของการจำแนกอารมณ์ และการตีความข้อความที่มีความกำกวมหรือซับซ้อนได้หรือไม่
- 5) เพื่อพัฒนาแนวทางต้นแบบในการประยุกต์ใช้ AI เพื่อสนับสนุนการทำความเข้าใจอารมณ์ในการสื่อสารระหว่างทันตแพทย์กับผู้ป่วย

1.3 ขอบเขตของโครงการ

- 1) ศึกษาและใช้ข้อมูลข้อความสนทนาที่เกี่ยวข้องกับบริบททางทันตกรรม หรือชุดข้อมูลที่ถูกปรับให้อยู่ในรูปแบบบทสนทนาระหว่างผู้ป่วยกับทันตแพทย์
- 2) ดำเนินการเตรียมข้อมูล (Data Preprocessing) ได้แก่ การทำความสะอาดข้อความ การตัดคำ และการแปลงข้อมูลให้อยู่ในรูปแบบที่เหมาะสมสำหรับการเรียนรู้ของโมเดล
- 3) พัฒนาโมเดล Machine Learning เช่น Logistic Regression, Random Forest และ Support Vector Machine รวมถึงโมเดล Deep Learning เช่น BiLSTM หรือโมเดลที่เหมาะสมกับงานวิเคราะห์ข้อความ
- 4) ประยุกต์ใช้ Artificial Intelligence หรือ Large Language Model ในลักษณะ Hybrid เพื่อช่วยตรวจสอบหรือปรับปรุงผลการทำนายของโมเดลหลัก
- 5) ประเมินประสิทธิภาพของโมเดลโดยใช้ตัวชี้วัด เช่น Accuracy, Precision, Recall และ F1-score
- 6) โครงการนี้มุ่งเน้นการวิเคราะห์ข้อความเท่านั้น โดยไม่ครอบคลุมการประมวลผลเสียงแบบ real-time และไม่ครอบคลุมการนำระบบไปใช้งานจริงในทางคลินิก

1.4 เครื่องมือที่ใช้

ในการพัฒนาโครงการนี้ ได้เลือกใช้เครื่องมือและเทคโนโลยีที่เหมาะสมสำหรับการวิเคราะห์ข้อความและการพัฒนาโมเดลปัญญาประดิษฐ์ โดยมีรายละเอียดดังนี้

1) ภาษาโปรแกรม Python

ได้แก่ ภาษาโปรแกรมหลักที่ใช้ในการพัฒนา เนื่องจากรองรับการทำงานด้าน Machine Learning, Deep Learning และการประมวลผลข้อมูลข้อความ

2) ไลบรารีสำหรับ Machine Learning

ได้แก่ Scikit-learn ซึ่งใช้สำหรับพัฒนาโมเดล เช่น Logistic Regression, Random Forest และ Support Vector Machine และ Naive Bayes รวมถึงใช้สำหรับการฝึกโมเดล การทำนายผล และการประเมินประสิทธิภาพของโมเดล

3) ไลบรารีสำหรับ Deep Learning

ได้แก่ TensorFlow และ Keras ซึ่งใช้สำหรับพัฒนาโมเดลเชิงลึก เช่น BiLSTM และโมเดลที่เหมาะสมกับงานวิเคราะห์ข้อความ

4) Large Language Model (LLM)

ได้แก่ Qwen2.5:7B-Instruct, Llama3.1:8b และ DeepSeek-R1:8B ซึ่งเป็นโมเดลภาษาขนาดใหญ่ที่ทำงานผ่านระบบ Ollama และมีความสามารถด้านการทำความเข้าใจและตีความภาษาธรรมชาติ โดยนำมาใช้ในแนวทาง Hybrid เพื่อช่วยตรวจสอบ วิเคราะห์ และปรับปรุงผลการทำนายของโมเดลหลัก โดยเฉพาะในกรณีที่ข้อความมีความกำกวมหรือซับซ้อน

5) เครื่องมือสำหรับการจัดการข้อมูล

ได้แก่ Pandas และ NumPy ซึ่งใช้สำหรับการจัดการข้อมูล การแปลงข้อมูล และการวิเคราะห์ข้อมูลในรูปแบบตารางและอาร์เรย์

6) เครื่องมือสำหรับการพัฒนาโปรแกรม

ได้แก่ Visual Studio Code ซึ่งใช้สำหรับการเขียนโปรแกรม แก้ไขโค้ด และจัดการไฟล์ภายในโครงการ

7) เครื่องมือสำหรับการทดลองและประมวลผลข้อมูล

ได้แก่ Jupyter Notebook ซึ่งใช้สำหรับการทดลองโมเดล การรันขั้นตอนการประมวลผลข้อมูล และการสรุปผลการทดลอง

8) เครื่องมือสำหรับการแสดงผลและวิเคราะห์ผลลัพธ์

ได้แก่ Matplotlib ซึ่งใช้สำหรับการสร้างกราฟและการแสดงผลการประเมินโมเดล เช่น Confusion Matrix

1.5 ประโยชน์ที่คาดว่าจะได้รับ

- 1) ทำให้เข้าใจแนวทางการวิเคราะห์อารมณ์จากข้อความ โดยใช้เทคนิค Machine Learning, Deep Learning และ Large Language Model (LLM)
- 2) ได้โมเดลสำหรับจำแนกอารมณ์จากข้อความสนทนาในบริบททางทันตกรรม ซึ่งสามารถใช้เป็นต้นแบบในการพัฒนาระบบที่เกี่ยวข้อง
- 3) ทำให้สามารถเปรียบเทียบประสิทธิภาพของโมเดลแต่ละประเภท ได้แก่ Machine Learning, Deep Learning และแนวทาง Hybrid ว่ามีความแตกต่างกันอย่างไร
- 4) เป็นแนวทางในการนำ Artificial Intelligence มาประยุกต์ใช้กับงานวิเคราะห์ข้อความ โดยเฉพาะในกรณีที่ข้อความมีความกำกวมหรือซับซ้อน
- 5) ช่วยสนับสนุนการทำความเข้าใจอารมณ์ของผู้ป่วยจากข้อความ ซึ่งอาจเป็นประโยชน์ต่อการสื่อสารระหว่างทันตแพทย์กับผู้ป่วย

บทที่ 2

ทฤษฎีและงานวิจัยที่เกี่ยวข้อง

ในการศึกษาครั้งนี้ ผู้วิจัยได้ทบทวนแนวคิด ทฤษฎี และงานวิจัยที่เกี่ยวข้องจากหนังสือวารสารวิชาการ และแหล่งข้อมูลออนไลน์ที่น่าเชื่อถือ เพื่อใช้เป็นกรอบแนวคิดในการพัฒนาโมเดลวิเคราะห์อารมณ์จากข้อความ โดยแบ่งเนื้อหาออกเป็น 3 ส่วนหลัก ได้แก่ (1) การเตรียมข้อมูลและการประมวลผลข้อความ (2) โมเดลและเทคนิคที่ใช้ในงานวิจัย และ (3) งานวิจัยที่เกี่ยวข้อง

2.1 การเตรียมข้อมูลและการประมวลผลข้อความ

2.1.1 การเตรียมข้อมูล

การเตรียมข้อมูลเป็นขั้นตอนที่มีความสำคัญอย่างยิ่งในกระบวนการพัฒนาโมเดลการเรียนรู้ของเครื่อง เนื่องจากข้อมูลข้อความมีลักษณะเป็นข้อมูลไม่มีโครงสร้าง ซึ่งมักปนเปื้อนด้วยสัญญาณรบกวน เช่น URL ตัวเลข และสัญลักษณ์พิเศษ หากไม่ผ่านกระบวนการทำความสะอาดก่อน โมเดลจะไม่สามารถเรียนรู้รูปแบบที่มีความหมายได้อย่างมีประสิทธิภาพ (Goodfellow et al., 2016) ในการศึกษาครั้งนี้ ดำเนินการปรับปรุงข้อมูลอย่างเป็นลำดับขั้น โดยเริ่มจากการคัดกรองเฉพาะข้อมูลที่มีผู้พูดเป็น "patient" เท่านั้น จากนั้นดำเนินการทำความสะอาดข้อความ (text cleaning) ซึ่งประกอบด้วยการแปลงตัวอักษรทั้งหมดเป็นตัวพิมพ์เล็ก การลบ URL การลบตัวเลข และการลบเครื่องหมายวรรคตอน เพื่อลดความหลากหลายที่ไม่จำเป็นและเพิ่มความสม่ำเสมอของข้อมูล

นอกจากนี้ ยังมีการจัดการปัญหาความไม่สมดุลของข้อมูล (class imbalance) โดยกำหนดจำนวนข้อมูลสูงสุดของคลาส "neutral" ไว้ที่ 500 ตัวอย่าง เนื่องจากคลาสดังกล่าวมีจำนวนมากกว่าคลาสอื่นอย่างมีนัยสำคัญ ซึ่งหากไม่ควบคุม อาจทำให้โมเดลเกิดความลำเอียงในการทำนายไปยังคลาสที่มีจำนวนมาก (Chawla et al., 2002)

2.1.2 การแบ่งชุดข้อมูล

การแบ่งชุดข้อมูลเป็นขั้นตอนพื้นฐานในการพัฒนาและประเมินประสิทธิภาพของโมเดล โดยมีวัตถุประสงค์เพื่อแยกข้อมูลออกเป็นส่วนสำหรับการฝึก การปรับแต่ง และการทดสอบ ซึ่งแสดงในรูปสมการได้ว่า

$$D = D_{train} \cup D_{val} \cup D_{test}$$

ในการศึกษานี้ใช้วิธี Stratified Sampling เพื่อรักษาสัดส่วนของแต่ละคลาสให้ใกล้เคียงกันในทุกชุดข้อมูล โดยแบ่งข้อมูลออกเป็นชุดฝึกร้อยละ 70 ชุดตรวจสอบร้อยละ 15 และชุดทดสอบร้อยละ 15 ซึ่ง Kohavi (1995) ได้แสดงให้เห็นว่าวิธีนี้ให้ผลการประเมินที่เสถียรและเชื่อถือได้กว่าการสุ่มแบบธรรมดา โดยข้อมูลทั้งสามชุดถูกแบ่งครั้งเดียวและใช้ร่วมกันในทุกโมเดล เพื่อให้การเปรียบเทียบผลลัพธ์มีความยุติธรรม

2.1.3 การแทนข้อความเชิงตัวเลขด้วย TF-IDF

การแทนข้อความเชิงตัวเลข (text representation) เป็นกระบวนการแปลงข้อความให้อยู่ในรูปแบบเวกเตอร์ตัวเลข เพื่อให้โมเดลสามารถนำไปประมวลผลได้ เทคนิคที่นำมาใช้กับโมเดล Machine Learning ในงานวิจัยนี้คือ TF-IDF (Term Frequency–Inverse Document Frequency) ซึ่งพัฒนาโดย Salton & Buckley (1988) โดยมีสูตรการคำนวณดังนี้

$$\text{TF-IDF}(t, d) = \text{TF}(t, d) \times \log \left(\frac{N}{df(t)} \right)$$

โดยที่ $\text{TF}(t, d)$ คือจำนวนครั้งที่คำ t ปรากฏในเอกสาร d , N คือจำนวนเอกสารทั้งหมด และ $df(t)$ คือจำนวนเอกสารที่มีคำ t ปรากฏอยู่ วิธีนี้ช่วยลดน้ำหนักของคำที่ปรากฏบ่อยแต่ไม่มีความหมายเฉพาะ และเพิ่มความสำคัญของคำที่มีลักษณะเฉพาะสำหรับแต่ละเอกสาร

ในการศึกษานี้กำหนดพารามิเตอร์โดยจำกัดคำศัพท์สูงสุด 10,000 คำ และใช้ n-gram ในช่วง (1, 2) เพื่อให้โมเดลสามารถเรียนรู้ความสัมพันธ์ระหว่างคำที่อยู่ติดกันได้ด้วย

2.1.4 การแทนข้อความด้วย Tokenizer และ Padding สำหรับ Deep Learning

สำหรับโมเดล Bidirectional LSTM ใช้กระบวนการแทนข้อความที่แตกต่างออกไป โดยแปลงข้อความเป็นลำดับของดัชนีคำด้วย Tokenizer ซึ่งกำหนดคลังคำศัพท์สูงสุด 10,000 คำ และใช้ token พิเศษ <OOV> สำหรับคำที่ไม่พบในคลังคำศัพท์ จากนั้นปรับความยาวของลำดับให้เท่ากันทุกตัวอย่างที่ความยาว 50 token ด้วยการเติม padding ท้ายลำดับ (post-padding)

และตัดลำดับที่ยาวเกินออก (post-truncating) เพื่อให้อินพุตของโมเดลมีขนาดสม่ำเสมอ (Manning et al., 2008)

2.2 โมเดลและเทคนิคที่ใช้ในงานวิจัย

2.2.1 การเรียนรู้แบบมีผู้สอน

การเรียนรู้แบบมีผู้สอน (supervised learning) เป็นแนวคิดพื้นฐานของการพัฒนาโมเดลในงานวิจัยนี้ โดยใช้ข้อมูลที่มีป้ายกำกับเพื่อฝึกโมเดลให้เรียนรู้ฟังก์ชัน $f: X \rightarrow Y$ ซึ่ง X คือข้อมูลอินพุตและ Y คือป้ายกำกับอาร์มณที่ต้องการทำนาย โมเดลจะพยายามลดค่า loss function เพื่อให้ทำนายข้อมูลใหม่ได้อย่างแม่นยำ (Mitchell, 1997) โดยในงานวิจัยนี้เป็นการจำแนกแบบหลายคลาส (multiclass classification) ที่โมเดลต้องเลือกคลาสอาร์มณที่เหมาะสมที่สุดจากตัวเลือกทั้งหมดที่มี

2.2.2 โมเดล Machine Learning สำหรับการจำแนกข้อความ

โมเดล Machine Learning ที่ใช้ในงานวิจัยนี้มีทั้งสิ้น 4 ประเภท โดยทุกโมเดลรับอินพุตจาก TF-IDF vectorizer และกำหนด class_weight="balanced" เพื่อรับมือกับความไม่สมดุลของข้อมูล

- Logistic Regression เป็นโมเดลสำหรับการจำแนกข้อมูลที่ใช้ในการประมาณค่าความน่าจะเป็นของแต่ละคลาส โดยในกรณีของปัญหาแบบสองคลาส (binary classification) จะใช้ฟังก์ชัน sigmoid ดังสมการ

$$P(y = 1 | x) = \frac{1}{1 + e^{-(w^T x + b)}}$$

อย่างไรก็ตาม ในงานวิจัยนี้เป็นการจำแนกแบบหลายคลาส (multiclass classification) จึงใช้รูปแบบ Multinomial Logistic Regression หรือ Softmax Regression ซึ่งใช้ฟังก์ชัน softmax ในการคำนวณความน่าจะเป็นของแต่ละคลาส ดังสมการ

$$P(y = j | x) = \frac{e^{w_j^T x}}{\sum_{k=1}^K e^{w_k^T x}}$$

โดยฟังก์ชัน softmax จะทำหน้าที่แปลงค่าคะแนนให้เป็น probability distribution ซึ่งผลรวมของความน่าจะเป็นของทุกคลาสเท่ากับ 1 และโมเดลจะเลือกคลาสที่มีค่าความน่าจะเป็นสูงที่สุดเป็นผลลัพธ์ของการทำนาย

โมเดลนี้มีข้อดีด้านความเรียบง่าย ดีความผลได้ง่าย และสามารถทำงานได้ดีในข้อมูลมิติสูง โดยในการศึกษานี้กำหนด max_iter = 2000 เพื่อให้โมเดลมีเวลาเพียงพอในการบรรจบสู่คำตอบ (Hastie et al., 2009)

- Naive Bayes เป็นโมเดลที่อาศัยทฤษฎีความน่าจะเป็นของ Bayes โดยมีสมมติฐานว่าคุณลักษณะแต่ละตัวเป็นอิสระต่อกัน (conditional independence) ซึ่งช่วยลดความซับซ้อนของการคำนวณ โดยสามารถเขียนในรูปแบบความน่าจะเป็นแบบมีเงื่อนไขได้ดังนี้

$$P(c | x) = \frac{P(x | c) \cdot P(c)}{P(x)}$$

แม้สมมติฐานดังกล่าวจะไม่สอดคล้องกับข้อมูลจริงเสมอไป แต่โมเดลยังคงให้ผลที่ดีในงานจำแนกข้อความ โดยเฉพาะข้อมูลที่มีมิติสูง เช่น ข้อมูลข้อความ (McCallum & Nigam, 1998)

ในการศึกษานี้ใช้ Multinomial Naive Bayes (MultinomialNB) ซึ่งเหมาะกับข้อมูลแบบนับความถี่ของคำ (เช่น TF-IDF หรือ Bag-of-Words) โดยโมเดลจะคำนวณ posterior probability ของแต่ละคลาสจากการกระจายของคำในข้อความ และเลือกคลาสที่มีความน่าจะเป็นสูงที่สุดเป็นผลลัพธ์

นอกจากนี้ ค่า posterior probability ที่ได้จากโมเดลยังสามารถนำมาใช้เป็น ค่า confidence ในขั้นตอนของ Hybrid Model เพื่อพิจารณาว่าควรใช้ผลจากโมเดลหลักหรือส่งต่อให้ LLM ประเมินเพิ่มเติม

- Support Vector Machine (SVM) เป็นโมเดลที่สร้างเส้นแบ่งกลุ่ม (hyperplane) เพื่อแยกข้อมูลออกเป็นคลาสต่าง ๆ ตามสมการ $w^T x + b = 0$ โดยมีเป้าหมายเพิ่ม margin ระหว่างกลุ่มข้อมูลให้สูงสุด และมีประสิทธิภาพสูงในข้อมูลมิติสูง (Cortes & Vapnik, 1995)

โดยทั่วไป SVM จะให้ผลลัพธ์เป็นค่า decision score หรือระยะห่างจากเส้นแบ่งกลุ่ม และ ไม่ได้ให้ probability โดยตรง อย่างไรก็ตาม สามารถแปลงค่า decision score ให้เป็นความน่าจะเป็นได้ด้วยเทคนิค Platt Scaling ซึ่งมีรูปแบบดังสมการ

$$P(y = 1 | x) = \frac{1}{1 + \exp(Af(x) + B)}$$

โดยที่ $f(x)$ คือค่า decision score และ A, B เป็นพารามิเตอร์ที่เรียนรู้จากข้อมูล ซึ่งเป็นการใช้ฟังก์ชัน sigmoid เพื่อปรับค่า score ให้เป็น probability (Platt, 1999)

ในการศึกษานี้กำหนด kernel="linear" และ probability=True เพื่อให้โมเดลสามารถประมาณค่าความน่าจะเป็นดังกล่าว ซึ่งสามารถนำไปใช้เป็นค่า confidence ในกลไก Hybrid ได้

Random Forest เป็นโมเดลแบบ ensemble ที่สร้างต้นไม้ตัดสินใจหลายต้นและรวมผลลัพธ์ด้วยการโหวต โดยสามารถเขียนได้ดังนี้

$$\hat{y} = \text{mode}(y_1, y_2, \dots, y_n)$$

ซึ่งช่วยลดปัญหา overfitting และเพิ่มความเสถียรของโมเดล (Breiman, 2001) โดยในการศึกษานี้กำหนด

$$n_estimators = 300$$

สำหรับการประมาณค่าความน่าจะเป็น โมเดลสามารถคำนวณได้จาก สัดส่วนของต้นไม้ตัดสินใจที่โหวตให้แต่ละคลาส หรือค่าเฉลี่ยของการทำนายจากแต่ละต้นไม้ ดังสมการ

$$P(y = c | x) = \frac{1}{n} \sum_{i=1}^n 1(y_i = c)$$

โดยที่ $1(\cdot)$ เป็นฟังก์ชัน indicator ซึ่งมีค่าเป็น 1 เมื่อเงื่อนไขเป็นจริง และ 0 เมื่อไม่เป็นจริง

ดังนั้น ค่า probability สูงสุดสามารถใช้เป็น ค่า confidence ของโมเดล และนำไปใช้ในกลไก Hybrid เพื่อพิจารณาว่าควรใช้ผลจากโมเดลหลักหรือส่งต่อให้โมเดลอื่นประเมินเพิ่มเติม

2.2.3 โมเดล Bidirectional LSTM

Long Short-Term Memory (LSTM) เป็นโมเดลประเภท Recurrent Neural Network ที่พัฒนาโดย Hochreiter & Schmidhuber (1997) เพื่อแก้ปัญหา vanishing gradient ในการเรียนรู้ข้อมูลลำดับ โมเดลมีโครงสร้างหลัก 4 ส่วน ได้แก่ cell state, forget gate, input gate และ output gate ซึ่งทำงานร่วมกันในการเลือกว่าจะจดจำหรือลืมข้อมูลในแต่ละขั้นตอน

ในการศึกษาครั้งนี้ใช้ Bidirectional LSTM ซึ่งเป็นการขยายความสามารถของ LSTM โดยประมวลผลลำดับข้อความทั้งจากซ้ายไปขวาและจากขวาไปซ้ายพร้อมกัน ทำให้โมเดลเข้าใจบริบทของข้อความได้ครบถ้วนทั้งสองทิศทาง (Schuster & Paliwal, 1997) โครงสร้างของโมเดลประกอบด้วย Embedding layer ขนาด 128 มิติ ตามด้วย Bidirectional LSTM จำนวน 64 หน่วย จากนั้นเป็น Dropout อัตรา 0.5 เพื่อป้องกัน overfitting และ Dense layer ที่ใช้ฟังก์ชัน softmax ในการแปลงผลลัพธ์เป็นความน่าจะเป็นของแต่ละคลาส

$$P(y_i) = \frac{e^{z_i}}{\sum_j e^{z_j}}$$

โมเดลฝึกด้วย categorical cross-entropy loss และ Adam optimizer โดยใช้ EarlyStopping ที่ตรวจสอบ val_loss ด้วยค่า patience=3 เพื่อหยุดการฝึกเมื่อประสิทธิภาพบนชุดตรวจสอบไม่ดีขึ้น

2.2.4 สถาปัตยกรรม Transformer และกลไก Attention

สถาปัตยกรรม Transformer ที่พัฒนาโดย Vaswani et al. (2017) ใช้กลไก Self-Attention เพื่อเรียนรู้ความสัมพันธ์ระหว่างคำทุกคำในประโยคพร้อมกัน แทนการประมวลผลแบบลำดับของ RNN ทำให้สามารถประมวลผลแบบขนานและเข้าใจบริบทระยะไกลได้ดีขึ้น

กลไก Attention สามารถเขียนได้ดังสมการ

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

โดยที่ Q, K, V คือเมทริกซ์ Query, Key และ Value ตามลำดับ ซึ่งใช้ในการคำนวณน้ำหนักความสำคัญของคำในประโยค สถาปัตยกรรมนี้เป็นพื้นฐานสำคัญของ Large Language Models (LLMs) ที่นำมาใช้ในโครงงานนี้

2.2.5 Large Language Models และการเรียนรู้แบบ Few-Shot

Large Language Models (LLMs) เป็นโมเดลภาษาขนาดใหญ่ที่ผ่านการฝึกด้วยข้อมูลจำนวนมาก ทำให้สามารถเข้าใจบริบทของภาษาได้ในระดับลึก และสามารถเรียนรู้ผ่านบริบท (in-context learning) ได้

โมเดลกลุ่มนี้รองรับการทำงานแบบ Few-Shot Learning ซึ่งเป็นการเรียนรู้จากตัวอย่างจำนวนน้อยที่อยู่ใน prompt โดยไม่ต้องปรับพารามิเตอร์ของโมเดล แตกต่างจาก Zero-Shot Learning ที่ไม่มีตัวอย่างประกอบ (Brown et al., 2020)

ในโครงงานนี้ ใช้ LLM ผ่าน Ollama API ในรูปแบบ OpenAI-compatible โดยทดสอบ 3 โมเดล ได้แก่ Llama3.1:8b, DeepSeek-R1:8B และ Qwen 2.5:7B-Instruct และกำหนดค่า temperature = 0 เพื่อให้ผลลัพธ์มีความสม่ำเสมอ

สำหรับการสร้าง few-shot prompt กำหนดตัวอย่าง 2 ตัวอย่างต่อคลาส โดยคัดเลือกจากชุดข้อมูลฝึกเท่านั้นเพื่อป้องกัน data leakage และจำกัดความยาวข้อความไม่เกิน 180 ตัวอักษร เพื่อควบคุมขนาดของ prompt

2.2.6 โมเดลแบบผสมผสาน (Hybrid Model)

โมเดลแบบผสมผสานเป็นแนวทางที่รวมข้อดีของโมเดลหลายประเภทเข้าด้วยกัน เพื่อเพิ่มประสิทธิภาพของระบบโดยรวม โดยอาศัยการรวมผลลัพธ์จากหลายโมเดลเพื่อลดความผิดพลาด (Dietterich, 2000)

ในโครงงานนี้ โมเดลพื้นฐาน (Machine Learning หรือ BiLSTM) จะทำการทำนายก่อน จากนั้นพิจารณาความมั่นใจ (confidence) ของผลลัพธ์ หากค่าดังกล่าวต่ำกว่าเกณฑ์ที่กำหนด จะส่งข้อความให้ Large Language Model (LLM) ทำการประเมินซ้ำ โดยสามารถเขียนได้ดังนี้

$$y_{\text{final}} = \begin{cases} y_{\text{model}}, & \text{if } \max (P(y | x)) \geq 0.70 \\ y_{\text{LLM}}, & \text{if } \max (P(y | x)) < 0.70 \end{cases}$$

โดยกำหนดให้

$$\text{confidence} = \max (P(y | x))$$

แนวทางนี้ช่วยลดการใช้งาน LLM ซึ่งมีต้นทุนสูง โดยเรียกใช้เฉพาะกรณีที่โมเดลหลักมีความไม่มั่นใจ และช่วยเพิ่มความแม่นยำของผลลัพธ์โดยรวม

2.2.7 ความสอดคล้องของโมเดล LLM ที่ใช้ในโครงงาน

ในการใช้งาน Large Language Models (LLMs) จำเป็นต้องระบุชื่อรุ่นของโมเดลให้ตรงกับที่ใช้จริง เนื่องจากโมเดลในตระกูลเดียวกันมีหลายขนาดและหลายเวอร์ชัน ซึ่งส่งผลต่อประสิทธิภาพของโมเดลอย่างมีนัยสำคัญ

ในโครงงานนี้เลือกใช้โมเดลขนาดประมาณ 1.5–8 พันล้านพารามิเตอร์ (1.5B–8B) เนื่องจากเป็นขนาดที่สมดุลระหว่างความสามารถในการเข้าใจบริบทภาษาและทรัพยากรที่ต้องการ กล่าวคือ สามารถรันบนฮาร์ดแวร์ระดับผู้ใช้ทั่วไปได้โดยไม่ต้องพึ่งพาบริการคลาวด์ราคาสูง นอกจากนี้ การรันผ่าน Ollama บนเครื่องภายในองค์กร (local deployment) ช่วยให้ข้อมูล

ผู้ป่วยที่ใช้ในการศึกษาไม่ถูกส่งออกนอกระบบ ซึ่งเป็นการคำนึงถึงความเป็นส่วนตัวและความปลอดภัยของข้อมูล

โมเดลที่ใช้งานในโครงการนี้ มีดังต่อไปนี้

- llama3.1:8b: Llama 3.1 ขนาด 8B พารามิเตอร์
- deepseek-r1:8b: DeepSeek-R1 ขนาด 8B พารามิเตอร์
- qwen2.5:1.5b-instruct: Qwen 2.5 ขนาด 1.5B พารามิเตอร์

โมเดลเหล่านี้เป็นส่วนหนึ่งของตระกูล LLM ที่มีหลายขนาด เช่น Llama 3.1 มีทั้ง 8B, 70B และ 405B พารามิเตอร์ และ DeepSeek-R1 มีหลายขนาดตั้งแต่ 1.5B ไปจนถึงระดับหลายร้อยพันล้านพารามิเตอร์

2.2.8 การประเมินผลโมเดล

การประเมินผลโมเดลในงานวิจัยนี้ใช้ตัวชี้วัดที่คำนวณจาก Confusion Matrix ซึ่งประกอบด้วย True Positive, True Negative, False Positive และ False Negative โดยตัวชี้วัดหลักที่ใช้ได้แก่ Accuracy, F1-Macro และ F1-Weighted (Sokolova & Lapalme, 2009)

$$F_1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

F1-Macro คำนวณค่า F1 ของแต่ละคลาสแล้วหาค่าเฉลี่ย โดยให้น้ำหนักเท่ากันทุกคลาส ซึ่งเหมาะสมสำหรับข้อมูลที่มีความไม่สมดุล เนื่องจากสะท้อนประสิทธิภาพของโมเดลต่อทุกคลาสอย่างเท่าเทียม ส่วน F1-Weighted คำนวณโดยถ่วงน้ำหนักตามจำนวนตัวอย่างในแต่ละคลาส ซึ่งสะท้อนประสิทธิภาพโดยรวมของระบบได้ดีกว่าการใช้ Accuracy เพียงอย่างเดียว นอกจากนี้ยังแสดง Confusion Matrix เพื่อวิเคราะห์รูปแบบความผิดพลาดของแต่ละโมเดลด้วย

2.3 งานวิจัยที่เกี่ยวข้อง

จากการทบทวนวรรณกรรมพบว่างานด้านการวิเคราะห์ข้อความและการจำแนกอารมณ์มีพัฒนาการอย่างต่อเนื่อง โดยสามารถจำแนกแนวทางหลักออกเป็น 3 กลุ่ม ได้แก่ Machine Learning แบบดั้งเดิม Deep Learning และ Large Language Models (LLMs) รวมถึงแนวทางแบบผสมผสาน ซึ่งมีเป้าหมายเพื่อเพิ่มความแม่นยำและลดข้อจำกัดของแต่ละวิธี

2.3.1 งานวิจัยด้าน Machine Learning

งานวิจัยด้านการวิเคราะห์อารมณ์จากข้อความ (Sentiment Analysis) ในช่วงเริ่มต้นมักใช้เทคนิค Machine Learning แบบ Supervised Learning โดยอาศัยการแปลงข้อความให้อยู่ในรูปแบบเชิงตัวเลข เช่น Bag-of-Words หรือ TF-IDF แล้วนำไปใช้ร่วมกับอัลกอริทึมจำแนกประเภท เช่น Naive Bayes, Logistic Regression และ Support Vector Machine (SVM)

จากงานวิจัยของ Pang et al. (2002) ได้ศึกษาเกี่ยวกับการจำแนกความคิดเห็นจากรีวิวภาพยนตร์ โดยพบว่าเทคนิค Machine Learning สามารถใช้จำแนกอารมณ์ของข้อความ (เชิงบวก/ลบ) ได้อย่างมีประสิทธิภาพ และ SVM เป็นหนึ่งในโมเดลที่ให้ผลลัพธ์ที่ดีเมื่อเทียบกับวิธีอื่น

นอกจากนี้ งานวิจัยจำนวนมากรวมถึงงานที่ปรากฏในคลังวิทยานิพนธ์ของจุฬาลงกรณ์มหาวิทยาลัย ได้แสดงให้เห็นว่า การใช้ SVM ร่วมกับการแปลงข้อความ เช่น TF-IDF สามารถให้ความแม่นยำสูงในการจำแนกอารมณ์ของข้อความ เนื่องจาก SVM สามารถจัดการกับข้อมูลที่มีมิติสูง (high-dimensional data) เช่น ข้อมูลข้อความได้เป็นอย่างดี และมีความสามารถในการสร้าง decision boundary ที่เหมาะสม

นอกจากนี้ งานวิจัยเชิงเปรียบเทียบยังระบุว่า SVM เป็นโมเดลที่ถูกนำมาใช้อย่างแพร่หลายในงาน sentiment analysis และให้ผลลัพธ์ที่มีความแม่นยำสูงเมื่อเทียบกับอัลกอริทึมอื่น เช่น Naive Bayes โดยเฉพาะในกรณีข้อมูลข้อความที่มีลักษณะซับซ้อน

อย่างไรก็ตาม แนวทาง Machine Learning ยังมีข้อจำกัดสำคัญคือไม่สามารถเข้าใจบริบทเชิงลึกของภาษาได้อย่างสมบูรณ์ ทำให้ในบางกรณีที่ข้อความมีความหมายแฝงหรือมีความซับซ้อนสูง โมเดลอาจให้ผลลัพธ์ที่คลาดเคลื่อนได้

2.3.2 งานวิจัยด้าน Deep Learning

เทคนิค Deep Learning เข้ามามีบทบาทในการแก้ข้อจำกัดดังกล่าว Kim (2014) เสนอการใช้ Convolutional Neural Network สำหรับการจำแนกประโยค และแสดงให้เห็นว่าสามารถให้ผลดีกว่าวิธีดั้งเดิมหลายวิธี ในขณะที่ Hochreiter & Schmidhuber (1997) พัฒนา LSTM ที่สามารถจดจำบริบทระยะไกลในข้อความได้ ซึ่ง Schuster & Paliwal (1997) ได้ขยายความสามารถดังกล่าวเป็น Bidirectional LSTM ทำให้เข้าใจบริบทได้ทั้งสองทิศทาง Ashbaugh & Zhang (2024) เปรียบเทียบ Machine Learning และ Deep Learning พบว่าโมเดล Deep Learning ให้ความแม่นยำสูงกว่าในกรณีที่มีข้อมูลจำนวนมาก แต่มีข้อจำกัดด้านต้นทุนทรัพยากรและความต้องการข้อมูลขนาดใหญ่

2.3.3 งานวิจัยด้าน Transformer และ Large Language Models

Vaswani et al. (2017) นำเสนอสถาปัตยกรรม Transformer ซึ่งกลายเป็นรากฐานของโมเดลภาษาสมัยใหม่ โดย Devlin et al. (2019) พัฒนา BERT ที่แสดงให้เห็นว่าโมเดล Transformer ให้ผลลัพธ์ที่เหนือกว่าโมเดลแบบดั้งเดิมในหลายงานด้าน NLP อย่างมีนัยสำคัญ Brown et al. (2020) นำเสนอ GPT-3 และแสดงให้เห็นความสามารถของ Few-Shot Learning ที่โมเดลสามารถทำงานใหม่ได้จากตัวอย่างจำนวนน้อยใน prompt โดยไม่ต้องฝึกเพิ่มเติม ซึ่งเปิดประตูสู่การประยุกต์ใช้ LLM ในงานจำแนกอารมณ์โดยไม่ต้องใช้ข้อมูลติดป้ายกำกับจำนวนมาก

2.3.4 งานวิจัยด้าน Hybrid Model

Ezen-Can (2020) แสดงให้เห็นว่าโมเดล LSTM มีประสิทธิภาพสูงกว่า BERT สำหรับชุดข้อมูลขนาดเล็ก สะท้อนว่าการเลือกโมเดลควรพิจารณาจากลักษณะและปริมาณของข้อมูลเป็นหลัก ไม่ใช่เลือกตามความซับซ้อนของโมเดลเพียงอย่างเดียว Xiang et al. (2020) นำเสนอ

กรอบการจำแนกอารมณ์ทางวิชาการโดยใช้ทั้ง CNN และ LSTM-ATT ร่วมกัน ซึ่งให้ผลการจำแนกดีกว่าการใช้โมเดลเดี่ยว สอดคล้องกับแนวคิดของ Dietterich (2000) ที่แสดงให้เห็นว่าการรวมโมเดลที่หลากหลายสามารถลดความผิดพลาดและเพิ่มความแม่นยำได้อย่างมีนัยสำคัญจากแนวโน้มดังกล่าว งานวิจัยในปัจจุบันจึงมุ่งเน้นการผสมผสานข้อดีของแต่ละแนวทาง โดยใช้ Machine Learning หรือ Deep Learning เป็นโมเดลหลัก และใช้ LLM เป็นตัวช่วยปรับปรุงผลลัพธ์ในกรณีที่มีความไม่แน่ใจ ซึ่งเป็นแนวทางเดียวกับที่นำมาใช้ในงานวิจัยนี้

บทที่ 3

วิธีการดำเนินโครงการ

3.1 ขั้นตอนการดำเนินงาน

การดำเนินโครงการนี้มีวัตถุประสงค์เพื่อพัฒนาระบบวิเคราะห์อารมณ์จากข้อความสนทนาในบริบททางทันตกรรม โดยประยุกต์ใช้เทคนิค Machine Learning, Deep Learning และแนวทาง Hybrid Model ร่วมกับ Large Language Model เพื่อเพิ่มประสิทธิภาพในการจำแนกอารมณ์ของข้อความ ทั้งนี้กระบวนการดำเนินงานได้ถูกออกแบบเป็นลำดับขั้นอย่างเป็นระบบ ดังนี้

1) การศึกษาปัญหาและกำหนดขอบเขต (Problem Definition)

เริ่มต้นจากการศึกษาปัญหาการวิเคราะห์อารมณ์ (Emotion Classification) ในข้อความสนทนา โดยมุ่งเน้นบริบทด้านทันตกรรม ซึ่งผู้ป่วยมักแสดงอารมณ์ เช่น ความกลัว ความกังวล และความเจ็บปวดผ่านการสื่อสาร

ในขั้นตอนนี้ได้มีการกำหนดรายละเอียดที่สำคัญ ได้แก่ ประเภทของอารมณ์ที่ต้องการจำแนก เช่น happy, sad, angry และ neutral รวมถึงกำหนดรูปแบบของข้อมูลให้อยู่ในลักษณะข้อความสนทนา (text-based conversation) และกำหนดขอบเขตของระบบให้มุ่งเน้นเฉพาะข้อมูลข้อความ โดยไม่ครอบคลุมข้อมูลเสียงหรือข้อมูลหลายรูปแบบ (multimodal)

2) การรวบรวมและคัดเลือกข้อมูล (Data Collection & Selection)

ข้อมูลที่ใช้ในโครงการถูกจัดเก็บในรูปแบบไฟล์ CSV ซึ่งประกอบด้วยข้อความ (utterance) และป้ายกำกับอารมณ์ (emotion label) จากนั้นจึงทำการคัดเลือกข้อมูลที่เหมาะสม โดยเน้นเฉพาะข้อความจากฝั่งผู้ป่วย (patient) เนื่องจากสามารถสะท้อนอารมณ์และความรู้สึกได้โดยตรงมากกว่าข้อความจากฝั่งทันตแพทย์

3) การเตรียมข้อมูล (Data Preprocessing)

ข้อมูลที่รวบรวมได้จะถูกนำมาปรับปรุงคุณภาพก่อนนำไปใช้ในการฝึกโมเดล โดยประกอบด้วยกระบวนการสำคัญ ได้แก่ การทำความสะอาดข้อความ (Text Cleaning) การปรับสมดุลข้อมูล (Data Balancing) การแปลงข้อความเป็นตัวแทนเชิงตัวเลข (Feature Representation) การเข้ารหัสป้ายกำกับ (Label Encoding) และการแบ่งข้อมูล (Data Splitting) ซึ่งรายละเอียดของแต่ละขั้นตอนจะอธิบายเพิ่มเติมในหัวข้อ 3.2

4) การพัฒนาโมเดล Machine Learning

ในขั้นตอนนี้ได้พัฒนาโมเดล Machine Learning เพื่อใช้เป็นแนวทางพื้นฐาน (baseline) สำหรับการจำแนกอารมณ์ โดยเลือกใช้โมเดลที่เหมาะสมกับงานวิเคราะห์ข้อความ ได้แก่ Logistic Regression, Support Vector Machine (SVM) และ Random Forest

ข้อมูลนำเข้าสู่โมเดลถูกแปลงด้วยเทคนิค TF-IDF และทำการประเมินผลด้วยตัวชี้วัด เช่น Accuracy และ F1-score

5) การพัฒนาโมเดล Deep Learning

พัฒนาโมเดล Deep Learning เพื่อเรียนรู้ลักษณะเชิงลำดับของภาษา โดยใช้โมเดลประเภท Long Short-Term Memory (LSTM) หรือ BiLSTM

ข้อมูลข้อความถูกแปลงให้อยู่ในรูปแบบลำดับ (sequence) ด้วย Tokenizer และปรับความยาวข้อมูลด้วย padding เพื่อให้สามารถนำเข้าสู่โมเดลได้อย่างเหมาะสม จากนั้นดำเนินการฝึกโมเดล และเปรียบเทียบผลลัพธ์กับ Machine Learning

6) การพัฒนาโมเดล Hybrid (Machine Learning / Deep Learning ร่วมกับ LLM)

ในขั้นตอนนี้ได้พัฒนาแนวทาง Hybrid Model โดยใช้โมเดล Machine Learning หรือ Deep Learning เป็นตัวทำนายหลัก และใช้ Large Language Model เช่น Qwen 2.5:7B-Instruct ในการตรวจสอบหรือปรับปรุงผลลัพธ์

กระบวนการทำงานประกอบด้วย

- โมเดลหลักทำการทำนายผลลัพธ์
- ส่งข้อความพร้อมผลลัพธ์ไปยัง LLM
- LLM วิเคราะห์ความสอดคล้องของข้อความกับป้ายกำกับ
- ปรับผลลัพธ์ในกรณีที่ ไม่สอดคล้อง

แนวทางดังกล่าวช่วยเพิ่มความแม่นยำของระบบ โดยเฉพาะในกรณีที่โมเดลหลักมีความไม่มั่นใจหรือเกิดความคลาดเคลื่อนในการตีความบริบทของภาษา

7) การประเมินผลโมเดล (Model Evaluation)

ทำการประเมินประสิทธิภาพของโมเดลแต่ละประเภท โดยใช้ตัวชี้วัด ได้แก่ Accuracy, Precision, Recall และ F1-score รวมถึงวิเคราะห์ผลลัพธ์ในระดับรายคลาส (per-class evaluation) และใช้ Confusion Matrix เพื่อศึกษาความสามารถในการจำแนกอารมณ์ในแต่ละประเภทอย่างละเอียด

8) การเปรียบเทียบผลลัพธ์ (Model Comparison)

นำผลลัพธ์ของโมเดลแต่ละประเภท ได้แก่ Machine Learning, Deep Learning และ Hybrid Model มาเปรียบเทียบ เพื่อวิเคราะห์แนวทางที่ให้ประสิทธิภาพดีที่สุด และเหมาะสมกับลักษณะของข้อมูลในโครงการนี้

9) การสรุปผลและจัดทำรายงาน (Conclusion and Reporting)

สรุปผลการดำเนินโครงการ วิเคราะห์ข้อดี ข้อจำกัด และแนวทางการพัฒนาเพิ่มเติมในอนาคต พร้อมจัดทำรายงานและนำเสนอผลลัพธ์

3.2 การเตรียมข้อมูล (Data Preprocessing)

การเตรียมข้อมูลเป็นขั้นตอนสำคัญในการพัฒนาโมเดลวิเคราะห์ข้อความ เนื่องจากข้อมูลข้อความดิบมีลักษณะไม่เป็นโครงสร้าง (Unstructured Data) และมักประกอบด้วยข้อมูลรบกวนจำนวนมาก เช่น เครื่องหมายพิเศษ คำที่ไม่เกี่ยวข้อง รูปแบบการเขียนที่ไม่สม่ำเสมอ หรือข้อมูลที่ไม่สมบูรณ์ ดังนั้น ก่อนนำข้อมูลไปใช้ในการฝึกโมเดล จึงจำเป็นต้องผ่านกระบวนการเตรียมข้อมูลเพื่อปรับปรุงคุณภาพข้อมูล และแปลงให้อยู่ในรูปแบบที่เหมาะสมกับการเรียนรู้ของโมเดลแต่ละประเภท โดยในโครงงานนี้ได้ดำเนินการดังนี้

1) แหล่งที่มาของข้อมูลและลักษณะข้อมูล

ข้อมูลที่ใช้ในโครงงานนี้เป็นข้อมูลข้อความสนทนาในบริบททางทันตกรรม ซึ่งจัดเก็บในรูปแบบไฟล์ CSV โดยมีองค์ประกอบหลัก ได้แก่ ข้อความบทสนทนา (utterance) และป้ายกำกับอารมณ์ (emotion label) ข้อมูลดังกล่าวเป็นข้อมูลภาษาธรรมชาติที่ไม่มีโครงสร้างแน่นอน และมีความหลากหลายในหลายด้าน เช่น รูปแบบการใช้ภาษา ความยาวของประโยค และบริบทของการสื่อสารระหว่างผู้ป่วยกับทันตแพทย์

ในการเตรียมข้อมูลสำหรับการวิเคราะห์อารมณ์ โครงงานนี้ได้คัดเลือกเฉพาะข้อความที่เป็นบทสนทนาของ ผู้ป่วย (patient) มาใช้เป็นข้อมูลหลักในการวิเคราะห์ เนื่องจากข้อความส่วนนี้สะท้อนอารมณ์ ความรู้สึก และสภาวะทางจิตใจของผู้ป่วยได้โดยตรงมากกว่าข้อความจากฝั่งทันตแพทย์ ซึ่งส่วนใหญ่มักเป็นข้อความเชิงสอบถาม อธิบาย หรือให้คำแนะนำ

2) การทำความสะอาดข้อมูล (Text Cleaning)

ข้อความดิบที่รวบรวมมาอาจมีองค์ประกอบที่ไม่จำเป็นต่อการเรียนรู้ของโมเดล เช่น อักขระพิเศษ ลิงก์ หรือรูปแบบข้อความที่ไม่สม่ำเสมอ ดังนั้น จึงมีการทำความสะอาดข้อมูลเพื่อลดสัญญาณรบกวน (noise) และทำให้ข้อมูลมีรูปแบบมาตรฐานมากขึ้น โดยมีรายละเอียดดังนี้แปลงข้อความทั้งหมดให้อยู่ในรูปแบบตัวพิมพ์เล็ก (lowercase)

- แปลงข้อความทั้งหมดให้อยู่ในรูปแบบตัวพิมพ์เล็ก (lowercase) เพื่อให้คำที่มีความหมายเดียวกันถูกนับเป็นคำเดียวกัน
- ลบ URL และข้อมูลที่ไม่เกี่ยวข้องกับเนื้อหาของบทความ
- ลบตัวอักษรพิเศษ เครื่องหมายวรรคตอน และตัวเลขที่ไม่จำเป็น
- ลบช่องว่างที่ซ้ำกัน (redundant whitespace) และจัดรูปแบบข้อความให้เป็นระเบียบ
- กรองข้อมูลที่เป็นค่าว่าง ข้อมูลซ้ำ หรือข้อมูลที่ไม่สมบูรณ์ออกจากชุดข้อมูล

กระบวนการดังกล่าวช่วยให้ข้อมูลมีความสม่ำเสมอมากขึ้น ลดความซับซ้อนของข้อความ และเพิ่มคุณภาพของข้อมูลก่อนนำไปสร้างคุณลักษณะหรือป้อนเข้าสู่โมเดล

3) การปรับสมดุลข้อมูล (Data Balancing)

จากการสำรวจข้อมูลพบว่าจำนวนตัวอย่างในแต่ละคลาสอาจมีการกระจายตัวไม่สมดุล โดยเฉพาะคลาส neutral ซึ่งมีจำนวนมากกว่าคลาสอื่นอย่างชัดเจน หากนำข้อมูลดังกล่าวไปใช้ฝึกโมเดลโดยตรง อาจทำให้โมเดลเกิดความเอนเอียง (bias) และทำนายคลาสที่มีจำนวนมากได้ดีกว่าคลาสส่วนน้อย

เพื่อแก้ไขปัญหาดังกล่าว โครงการนี้จึงใช้แนวทางปรับสมดุลข้อมูล ดังนี้

- จำกัดจำนวนข้อมูลในคลาสที่มีจำนวนมาก เช่น neutral ด้วยวิธีการสุ่มตัวอย่าง (random sampling)
- ใช้เทคนิค SMOTE (Synthetic Minority Over-sampling Technique) เพื่อเพิ่มจำนวนตัวอย่างของคลาสที่มีข้อมูลน้อยในชุดฝึก

แนวทางนี้ช่วยให้ชุดข้อมูลมีความสมดุลมากขึ้น ส่งผลให้โมเดลสามารถเรียนรู้ลักษณะของแต่ละอารมณ์ได้ดีขึ้น และลดปัญหาการทำนายที่เอนเอียงไปยังคลาสหลัก

4) การแปลงข้อมูลสำหรับ Machine Learning

โมเดล Machine Learning ไม่สามารถรับข้อมูลข้อความดิบได้โดยตรง จึงจำเป็นต้องแปลงข้อความให้อยู่ในรูปแบบเชิงตัวเลขก่อน ในโครงงานนี้ได้เลือกใช้เทคนิค TF-IDF (Term Frequency–Inverse Document Frequency) ซึ่งเป็นวิธีการแปลงข้อความเป็นเวกเตอร์เชิงตัวเลข โดยสะท้อนความสำคัญของคำในแต่ละข้อความเมื่อเทียบกับทั้งชุดข้อมูล

ในการสร้างคุณลักษณะด้วย TF-IDF มีการกำหนดรายละเอียดสำคัญดังนี้

- ใช้ n-gram ในช่วง 1 ถึง 2 ได้แก่ unigram และ bigram เพื่อให้โมเดลสามารถเรียนรู้ทั้งคำเดี่ยวและความสัมพันธ์ของคำที่ปรากฏติดกัน
- จำกัดจำนวนคุณลักษณะ (feature dimension) เพื่อควบคุมขนาดของข้อมูลและลดความซับซ้อนของโมเดล
- กรองคำที่มีความถี่ต่ำมากหรือสูงมากเกินไป เพื่อให้เหลือเฉพาะคำที่มีประโยชน์ต่อการจำแนกอารมณ์

ผลลัพธ์ที่ได้คือเวกเตอร์เชิงตัวเลขที่สามารถนำไปใช้เป็นข้อมูลนำเข้าสำหรับโมเดล Machine Learning ได้โดยตรง

5) การแปลงข้อมูลสำหรับ Deep Learning

สำหรับโมเดล Deep Learning ข้อความจะถูกแปลงให้อยู่ในรูปแบบลำดับของตัวเลข (sequence of tokens) เพื่อให้โมเดลสามารถเรียนรู้ลักษณะเชิงลำดับของภาษาได้ ในโครงงานนี้ใช้ Tokenizer ของ Keras ในการแปลงข้อความ โดยมีกระบวนการดังนี้

- สร้างคลังคำศัพท์ (vocabulary) จากข้อมูลชุดฝึก
- แปลงข้อความแต่ละประโยคให้อยู่ในรูปแบบลำดับของดัชนีคำ (text-to-sequence)
- กำหนดความยาวสูงสุดของข้อความ (maximum sequence length)
- เติมค่า (padding) ให้ข้อมูลทุกตัวอย่างมีความยาวเท่ากัน

การกำหนดความยาวของ sequence พิจารณาจากการกระจายตัวของความยาวข้อความจริงในชุดข้อมูล เช่น การอ้างอิงค่า percentile เพื่อให้ได้ความยาวที่ครอบคลุมข้อมูลส่วนใหญ่โดยไม่ยาวเกินความจำเป็น วิธีการดังกล่าวช่วยลดภาระในการคำนวณ และลดโอกาสสูญเสียข้อมูลสำคัญจากการตัดข้อความมากเกินไป

6) การแปลงค่า Label (Label Encoding)

ป้ายกำกับอารมณ์ในชุดข้อมูลเดิมอยู่ในรูปแบบข้อความ เช่น happy, sad, angry และ neutral ซึ่งไม่สามารถนำไปใช้ในการฝึกโมเดลได้โดยตรง จึงต้องมีการแปลงให้อยู่ในรูปแบบเชิงตัวเลข ด้วยวิธี Label Encoding เพื่อให้แต่ละคลาสมีรหัสแทนที่ชัดเจน

สำหรับโมเดล Deep Learning มีการแปลงค่าป้ายกำกับเพิ่มเติมให้อยู่ในรูปแบบ One-Hot Encoding เนื่องจากเหมาะสมกับการคำนวณในโครงข่ายประสาทเทียม และช่วยให้โมเดลสามารถเรียนรู้ความแตกต่างระหว่างคลาสได้อย่างมีประสิทธิภาพมากขึ้น

7) การแบ่งข้อมูล (Data Splitting)

หลังจากเตรียมข้อมูลเรียบร้อยแล้ว ข้อมูลจะถูกแบ่งออกเป็น 3 ส่วน ได้แก่

- ชุดฝึก (Training Set)
- ชุดตรวจสอบ (Validation Set)
- ชุดทดสอบ (Test Set)

ในการแบ่งข้อมูล โครงการนี้ใช้วิธี Stratified Sampling เพื่อรักษาสัดส่วนของแต่ละคลาสอารมณ์ให้ใกล้เคียงกันในทุกชุดข้อมูล วิธีการนี้ช่วยให้ข้อมูลแต่ละชุดมีการกระจายตัวของคลาสที่สมดุล และทำให้ผลการประเมินโมเดลมีความน่าเชื่อถือมากขึ้น

การแบ่งข้อมูลลักษณะนี้ยังช่วยให้สามารถใช้ชุด Validation ในการปรับแต่งโมเดล และใช้ชุด Test ในการประเมินผลขั้นสุดท้ายได้อย่างชัดเจน ซึ่งเป็นแนวทางที่ช่วยลดปัญหา overfitting และทำให้การวัดประสิทธิภาพของโมเดลสะท้อนความสามารถในการใช้งานจริงได้ดียิ่งขึ้น

3.3 การพัฒนาโมเดล Machine Learning

3.3.1 การเตรียมข้อมูลสำหรับโมเดล (Data Preparation for Modeling)

ข้อมูลที่ผ่านมากระบวนการทำความสะอาดแล้วถูกนำมาใช้งานโดยอ่านจากไฟล์ `cleaned_emotions_shared.csv` และใช้ไฟล์ `shared_split.json` ในการกำหนดการแบ่งข้อมูลออกเป็น 3 ส่วน ได้แก่ ชุดฝึก (Training Set) ชุดตรวจสอบ (Validation Set) และชุดทดสอบ (Test Set) ในสัดส่วน 70%, 15% และ 15% ตามลำดับ

การแบ่งข้อมูลดังกล่าวอ้างอิงจาก `row_id` เพื่อให้มั่นใจว่าไม่มีข้อมูลซ้ำระหว่างแต่ละชุด ซึ่งช่วยลดความเสี่ยงของการเกิดข้อมูลรั่วไหล (data leakage) และทำให้การประเมินผลโมเดลมีความน่าเชื่อถือมากยิ่งขึ้น

3.3.2 การแปลงข้อความเป็นตัวเลข (Feature Extraction)

เนื่องจากโมเดล Machine Learning ไม่สามารถประมวลผลข้อมูลข้อความโดยตรงได้ จึงจำเป็นต้องแปลงข้อความให้อยู่ในรูปแบบเชิงตัวเลข โดยในงานวิจัยนี้เลือกใช้เทคนิค TF-IDF (Term Frequency-Inverse Document Frequency) ซึ่งสามารถสะท้อนความสำคัญของคำในแต่ละเอกสารเมื่อเปรียบเทียบกับทั้งชุดข้อมูลได้อย่างมีประสิทธิภาพ

ในการสร้างคุณลักษณะ มีการกำหนดพารามิเตอร์ที่สำคัญ ได้แก่ การจำกัดจำนวนคุณลักษณะสูงสุด (`max_features`) ที่ 10,000 เพื่อลดความซับซ้อนของโมเดล และกำหนดช่วงของ `n-gram` เป็น (1, 2) เพื่อให้โมเดลสามารถเรียนรู้ทั้งคำเดี่ยว (unigram) และความสัมพันธ์ของคำที่ปรากฏติดกัน (bigram)

นอกจากนี้ ได้ทำการเรียนรู้เวกเตอร์จากข้อมูลชุดฝึกด้วยฟังก์ชัน `fit_transform()` และใช้ฟังก์ชัน `transform()` กับชุด `validation` และ `test` เพื่อให้กระบวนการแปลงข้อมูลมีความสอดคล้องกัน และป้องกันการเกิด data leakage

3.3.3 โมเดลที่ใช้ (Model Selection)

ในการพัฒนาโมเดลสำหรับการจำแนกอารมณ์จากข้อความ ได้ทำการทดลองโมเดลทั้งหมด 4 ประเภท เพื่อเปรียบเทียบประสิทธิภาพและเลือกแนวทางที่เหมาะสมที่สุดกับลักษณะของข้อมูล

3.3.3.1 Naive Bayes (MultinomialNB)

เป็นโมเดลพื้นฐานที่อาศัยหลักความน่าจะเป็น และได้รับความนิยมอย่างแพร่หลายในงานด้านการประมวลผลภาษาธรรมชาติ โดยเฉพาะกับข้อมูลที่อยู่ในรูปแบบ Bag-of-Words หรือ TF-IDF โมเดลนี้มีข้อดีคือสามารถประมวลผลได้รวดเร็ว ใช้ทรัพยากรต่ำ และให้ผลลัพธ์ที่ดีในงานจำแนกข้อความทั่วไป

3.3.3.2 Logistic Regression

เป็นโมเดลเชิงเส้นที่สามารถใช้จำแนกข้อมูลได้ทั้งแบบ binary และ multi-class โดยมีความสามารถในการเรียนรู้ความสัมพันธ์ระหว่างคุณลักษณะกับคลาสได้อย่างมีประสิทธิภาพ ในการทดลองนี้ได้กำหนดค่า `max_iter = 2000` เพื่อให้โมเดลมีจำนวนรอบการเรียนรู้เพียงพอสำหรับการหาค่าที่เหมาะสม และใช้ `class_weight = "balanced"` เพื่อจัดการกับปัญหาความไม่สมดุลของข้อมูล ซึ่งช่วยลดการเอนเอียงของโมเดลไปยังคลาสที่มีจำนวนตัวอย่างมาก

3.3.3.3 Random Forest

เป็นโมเดลแบบ Ensemble ที่ประกอบด้วย Decision Tree หลายต้น โดยใช้หลักการรวมผลลัพธ์จากหลายโมเดลย่อยเพื่อเพิ่มความแม่นยำและลดปัญหา overfitting ในการตั้งค่าโมเดลนี้ได้กำหนดจำนวนต้นไม้ (`n_estimators`) เท่ากับ 300 เพื่อเพิ่มความเสถียรของผลลัพธ์ และใช้ `class_weight = "balanced"` เพื่อรองรับข้อมูลที่มีการกระจายตัวไม่สมดุล

3.3.3.4 Support Vector Machine (SVM)

เป็นโมเดลที่มีประสิทธิภาพสูงสำหรับข้อมูลที่มีมิติสูง เช่น ข้อมูลจาก TF-IDF โดยเลือกใช้ kernel แบบเชิงเส้น (linear) ซึ่งเหมาะสมกับลักษณะของข้อมูลดังกล่าว นอกจากนี้ยัง

เปิดใช้งาน `probability = True` เพื่อให้สามารถคำนวณค่าความน่าจะเป็นของผลลัพธ์ได้ และใช้ `class_weight = "balanced"` เพื่อแก้ปัญหา `class imbalance` เช่นเดียวกับโมเดลอื่น

3.3.4 การฝึกโมเดล (Model Training)

ในขั้นตอนนี้ ได้ดำเนินการฝึกโมเดลโดยทำการวนลูปผ่านโมเดลแต่ละประเภทที่กำหนดไว้ โดยใช้ข้อมูลจากชุดฝึก (Training Set) เป็นหลัก

กระบวนการฝึกประกอบด้วยการใช้คำสั่ง `model.fit(X_train, y_train)` เพื่อเรียนรู้รูปแบบของข้อมูล พร้อมทั้งบันทึกเวลาในการฝึกของแต่ละโมเดลเพื่อนำไปเปรียบเทียบกับประสิทธิภาพในด้านเวลา นอกจากนี้ ยังมีการนำโมเดลที่ฝึกแล้วไปทำนายผลบนชุด `validation` และ `test` เพื่อใช้ในการประเมินผลในขั้นตอนถัดไป

3.3.5 การประเมินผลโมเดล (Model Evaluation)

การประเมินประสิทธิภาพของโมเดลดำเนินการโดยใช้ตัวชี้วัดหลัก ได้แก่ `Accuracy` และ `F1-score (macro average)`

โดย `Accuracy` ใช้ในการวัดสัดส่วนของการทำนายที่ถูกต้องโดยรวม ขณะที่ `F1-score (macro)` ถูกเลือกใช้เพื่อสะท้อนประสิทธิภาพของโมเดลในทุกคลาสอย่างเท่าเทียมกัน ซึ่งมีความเหมาะสมอย่างยิ่งในกรณีที่ข้อมูลมีความไม่สมดุลระหว่างคลาส

3.3.6 การบันทึกผลลัพธ์ (Result Saving)

หลังจากการฝึกและประเมินผลโมเดลเสร็จสิ้น ได้มีการบันทึกผลลัพธ์ที่สำคัญเพื่อรองรับการนำไปใช้งานในขั้นตอนถัดไป

ข้อมูลที่ถูกบันทึกประกอบด้วย `vectorizer` ซึ่งถูกจัดเก็บด้วย `joblib.dump()` เพื่อใช้ในการแปลงข้อมูลใหม่ในอนาคต รวมถึง `metadata` ที่เกี่ยวข้อง เช่น `label` และ `path` ต่าง ๆ ซึ่งถูกจัดเก็บในรูปแบบ `JSON` นอกจากนี้ยังมีการบันทึกผลการทำนายของชุด `test` และสรุปผลลัพธ์ของโมเดลแต่ละตัว โดยเรียงลำดับตามค่า `Accuracy` และ `F1-score` เพื่อให้สามารถเปรียบเทียบได้อย่างชัดเจน

3.3.7 การจัดการปัญหา Class Imbalance

เนื่องจากชุดข้อมูลมีการกระจายตัวของคลาสที่ไม่สมดุล เช่น คลาส neutral มีจำนวนตัวอย่างมากกว่าคลาสอื่นอย่างชัดเจน จึงจำเป็นต้องมีการจัดการปัญหาดังกล่าวเพื่อป้องกันไม่ให้โมเดลเกิดความเอนเอียงในการทำนาย

ในโครงงานนี้ ได้เลือกใช้วิธีการกำหนด `class_weight = "balanced"` ในโมเดลที่รองรับเพื่อปรับน้ำหนักของแต่ละคลาสให้เหมาะสม วิธีการนี้ช่วยให้โมเดลให้ความสำคัญกับคลาสที่มีจำนวนน้อยมากขึ้น ส่งผลให้ประสิทธิภาพโดยรวมของการจำแนกมีความสมดุลและแม่นยำยิ่งขึ้น

3.4 การพัฒนาโมเดล Deep Learning

3.4.1 โครงสร้างโมเดล (Model Architecture)

ในโครงงานนี้ได้เลือกใช้โมเดลประเภท Bidirectional Long Short-Term Memory (BiLSTM) ซึ่งเหมาะสมสำหรับการประมวลผลข้อมูลข้อความที่มีลักษณะเป็นลำดับ (sequence data) โดยสามารถเรียนรู้บริบทของคำได้ทั้งจากด้านหน้าและด้านหลังของประโยค ส่งผลให้โมเดลสามารถเข้าใจความหมายของข้อความได้อย่างครอบคลุมมากยิ่งขึ้น

โครงสร้างของโมเดลประกอบด้วยองค์ประกอบหลักดังนี้

- Embedding Layer

ทำหน้าที่แปลง token หรือดัชนีของคำให้อยู่ในรูปแบบเวกเตอร์เชิงความหมาย (semantic vector) เพื่อให้โมเดลสามารถเรียนรู้ความสัมพันธ์ของคำได้อย่างมีประสิทธิภาพ

- Bidirectional LSTM Layer

ช่วยให้โมเดลสามารถเรียนรู้ลำดับของคำในทั้งสองทิศทาง (forward และ backward) ซึ่งมีความสำคัญต่อการตีความบริบทของข้อความ

- Dropout Layer

ใช้เพื่อลดปัญหา overfitting โดยการสุมปิดการทำงานของบาง node ระหว่างการฝึกโมเดล

- Dense Layer (Output Layer)

เป็นชั้นสุดท้ายของโมเดล โดยใช้ activation function แบบ softmax เพื่อทำการจำแนกข้อมูลออกเป็นหลายคลาส

3.4.2 การกำหนดพารามิเตอร์ (Hyperparameters)

ในการพัฒนาโมเดล ได้มีการกำหนดค่าพารามิเตอร์ที่สำคัญ ซึ่งมีผลต่อประสิทธิภาพของโมเดล ดังนี้

- Embedding dimension ใช้กำหนดขนาดของเวกเตอร์คำ
- LSTM units เช่น 64 หรือ 128 เพื่อควบคุมความสามารถในการเรียนรู้ของโมเดล
- Dropout rate เช่น 0.3 – 0.5 เพื่อลดปัญหา overfitting
- Batch size กำหนดจำนวนตัวอย่างที่ใช้ในแต่ละรอบของการฝึก
- Epochs จำนวนรอบในการฝึกโมเดล

ค่าพารามิเตอร์เหล่านี้ได้รับการปรับแต่งผ่านการทดลอง เพื่อหาค่าที่เหมาะสมที่สุดสำหรับชุดข้อมูลในโครงการนี้

3.4.3 การฝึกโมเดล (Model Training)

โมเดลถูกฝึกด้วยข้อมูลจากชุดฝึก (Training Set) โดยใช้ฟังก์ชัน loss แบบ categorical crossentropy ซึ่งเหมาะสำหรับปัญหาการจำแนกหลายคลาส และใช้ตัวปรับค่า (optimizer) แบบ Adam ซึ่งมีประสิทธิภาพในการปรับค่าน้ำหนักของโมเดล

ในระหว่างการฝึก มีการใช้ชุดข้อมูล validation เพื่อตรวจสอบประสิทธิภาพของโมเดล ในแต่ละ epoch ซึ่งช่วยในการติดตามการเรียนรู้ของโมเดล และลดความเสี่ยงของการเกิด overfitting

3.4.4 การประเมินผลโมเดล (Model Evaluation)

หลังจากการฝึกโมเดลเสร็จสิ้น ได้ทำการประเมินผลโดยใช้ชุดข้อมูลทดสอบ (Test Set) เพื่อวัดความสามารถในการจำแนกข้อมูลใหม่

ตัวชี้วัดที่ใช้ในการประเมิน ได้แก่

- Accuracy
- Precision
- Recall
- F1-score
- Confusion Matrix

เนื่องจากข้อมูลมีลักษณะไม่สมดุล (class imbalance) ค่า F1-score จึงถูกให้ความสำคัญมากกว่า Accuracy เนื่องจากสามารถสะท้อนสมดุลระหว่าง precision และ recall ได้ดีกว่า

3.4.5 การจัดการปัญหา Class Imbalance และ Overfitting

การจัดการปัญหา Class Imbalance

เนื่องจากจำนวนตัวอย่างในแต่ละคลาสมีความไม่เท่ากัน เช่น คลาส neutral มีจำนวนมากกว่าคลาสอื่น จึงได้มีการจัดการโดย

- การปรับสมดุลข้อมูล (data balancing) ในขั้นตอน preprocessing

- การกำหนด class weight ระหว่างการฝึกโมเดล เพื่อให้โมเดลไม่เอนเอียงไปยังคลาสที่มีจำนวนมาก

การจัดการปัญหา Overfitting

เพื่อให้โมเดลสามารถนำไปใช้งานกับข้อมูลใหม่ได้ดี (generalization) ได้มีการใช้แนวทางดังนี้

- การใช้ Dropout Layer
- การใช้ Validation Set ในการตรวจสอบระหว่างการฝึก
- การปรับจำนวน epoch ให้เหมาะสมกับลักษณะของข้อมูล

3.5 การพัฒนาโมเดล Hybrid (Machine Learning / Deep Learning ร่วมกับ LLM)

ในการดำเนินงานส่วนนี้ ผู้จัดทำได้พัฒนาแนวทางการจำแนกอารมณ์แบบไฮบริด (Hybrid Approach) โดยมีวัตถุประสงค์เพื่อเพิ่มความแม่นยำในการพยากรณ์ และลดข้อจำกัดของแบบจำลองพื้นฐาน (Baseline Models) ซึ่งโดยทั่วไปมักมีข้อจำกัดด้านการเข้าใจบริบทในกรณีข้อความที่มีความซับซ้อนหรือคลุมเครือ

แนวทางที่พัฒนาขึ้นอาศัยการผสมผสานระหว่างแบบจำลอง Machine Learning (ML) และ Deep Learning (DL) ที่ผ่านการฝึกฝนแล้ว ร่วมกับ Large Language Model (LLM) เพื่อทำหน้าที่ตรวจสอบและปรับปรุงผลลัพธ์ในขั้นตอนการทดสอบ (Inference Phase) โดยไม่มีการฝึกโมเดลเพิ่มเติมในส่วนนี้

3.5.1 แนวคิดและสถาปัตยกรรมแบบไฮบริด (Hybrid Architecture)

สถาปัตยกรรมของระบบถูกออกแบบเพื่อแก้ปัญหา “ความไม่มั่นใจของแบบจำลอง” (Model Uncertainty) โดยใช้แนวคิด Confidence-based Refinement ซึ่งแบ่งการทำงานออกเป็น 2 ระดับ (Tier) ได้แก่

Tier 1 — Baseline Classifiers (Speed-Oriented)

เป็นแบบจำลองที่ผ่านการฝึกฝนจากขั้นตอนก่อนหน้านี้ (หัวข้อ 3.3 และ 3.4) ทำหน้าที่เป็นตัวพยากรณ์หลัก โดยเน้นความรวดเร็วในการประมวลผล ประกอบด้วย

- Machine Learning
ได้แก่ Logistic Regression (LR), Random Forest (RF) และ Support Vector Machine (SVM) ซึ่งใช้ TF-IDF เป็นตัวแปลงข้อมูล (Feature Extractor)
- Deep Learning
ได้แก่ Bidirectional Long Short-Term Memory (BiLSTM) ซึ่งสามารถเรียนรู้ลำดับของคำและบริบทของข้อความได้ดีกว่าในระดับหนึ่ง

Tier 2 — LLM Refiners (Accuracy-Oriented)

ในกรณีที่ผลลัพธ์จาก Tier 1 มีค่าความเชื่อมั่นต่ำ ระบบจะส่งข้อมูลไปยังแบบจำลองภาษาขนาดใหญ่ (LLM) เพื่อทำการวิเคราะห์เชิงลึก (Deep Contextual Analysis) โมเดล LLM ที่ใช้ในโครงงานนี้ประกอบด้วย

- Llama 3.1 (8B parameters): llama3.1:8b
- DeepSeek-R1 (8B parameters): deepseek-r1:8b
- Qwen 2.5 (7B parameters): qwen2.5:7b-instruct

โดยโมเดลทั้งหมดถูกใช้งานผ่านระบบ Ollama ในรูปแบบ Local Deployment ซึ่งช่วยให้ข้อมูลไม่ถูกส่งออกไปยังภายนอกระบบ

3.5.2 กลไกการประเมินค่าความเชื่อมั่น (Confidence Threshold Mechanism)

หัวใจสำคัญของระบบไฮบริดคือการใช้ค่าความเชื่อมั่น (Confidence Score) เพื่อกำหนดเส้นทางการประมวลผล

ค่า confidence ถูกนิยามจากค่าความน่าจะเป็นสูงสุดของแต่ละคลาส ดังนี้

$$Confidence(x) = \max P(y | x), y \in Y$$

โดยกำหนดค่าเกณฑ์ (Threshold) เท่ากับ

$$Threshold = 0.70$$

ซึ่งจากการทดลองเบื้องต้นพบว่าเป็นจุดสมดุลระหว่าง

- ความแม่นยำของระบบ
- และเวลาในการประมวลผล

เงื่อนไขการตัดสินใจมีดังนี้

- หาก $Confidence \geq 0.70$ ระบบจะยอมรับผลลัพธ์จาก Baseline Model ทันที
- หาก $Confidence < 0.70$ ระบบจะส่งข้อมูลไปยัง LLM เพื่อทำการปรับผลลัพธ์

3.5.3 การสร้างระบบธนาคารตัวอย่าง (Few-shot Bank Construction)

เพื่อให้ LLM สามารถจำแนกอารมณ์ได้ตรงตามขอบเขตของชุดข้อมูลในการศึกษา ผู้จัดทำได้พัฒนาฟังก์ชัน `build_few_shot_bank` สำหรับสร้างคลังตัวอย่างแบบ Dynamic จาก Training Set เท่านั้น เพื่อป้องกันปัญหา Data Leakage โดยมีหลักการออกแบบดังนี้

- Stratified Sampling: สุ่มตัวอย่าง 2 ข้อความต่อ 1 ประเภทอารมณ์ เพื่อให้ครอบคลุมทุกคลาส (รวม 12 ตัวอย่างต่อการเรียกครั้งหนึ่ง)
- Text Constraint: จำกัดความยาวข้อความตัวอย่างที่ 180 ตัวอักษร เพื่อป้องกัน Context Lost ใน Prompt

- Minimum Length Filter: กรองตัวอย่างที่สั้นกว่า 15 ตัวอักษรออก เพื่อคัดเลือกตัวอย่างที่มีความหมายเพียงพอ
- Fixed Seed: กำหนด Random State เป็น 42 เพื่อให้ผลการทดลองสามารถทำซ้ำได้ (Reproducibility)

3.5.4 การออกแบบวิศวกรรมคำสั่ง (Hybrid Prompt Engineering)

คำสั่งที่ส่งให้ LLM ในฟังก์ชัน Refine ถูกออกแบบเป็น Structured Prompt เพื่อควบคุมรูปแบบของผลลัพธ์ให้มีความสม่ำเสมอ ลดความคลาดเคลื่อน และสามารถนำไปใช้งานต่อในระบบได้ทันที โดยองค์ประกอบของ Prompt ถูกกำหนดอย่างเป็นระบบเพื่อช่วยให้โมเดลเข้าใจบริบทของงานได้อย่างชัดเจน

โครงสร้างของ Prompt ประกอบด้วย 4 ส่วนหลัก ได้แก่

1) System Instruction

ระบุบทบาทของ LLM ให้เป็น “Emotion Classification Assistant” และกำหนดชุดของอารมณ์ (Allowed Labels) อย่างชัดเจน ได้แก่ (angry, disgust, fear, happy, neutral, sad) เพื่อจำกัดขอบเขตการตอบและป้องกันการสร้างคำตอบนอกเหนือจากที่ระบบรองรับ

2) Few-shot Examples

เป็นตัวอย่างข้อความพร้อม label ที่สุ่มมาจาก Training Set ซึ่งช่วยให้ LLM เข้าใจรูปแบบของข้อมูลจริง และเรียนรู้ลักษณะของแต่ละอารมณ์ในบริบทที่ใกล้เคียงกับงานจริง ส่งผลให้การจำแนกมีความแม่นยำมากขึ้น

3) Current Task

ระบุข้อความที่ต้องการจำแนก พร้อมผลลัพธ์ (Predicted Label) จาก Baseline Model เพื่อให้ LLM ทำหน้าที่เป็นตัวตรวจสอบ (Verification) โดยพิจารณาว่าผลลัพธ์เดิมเหมาะสมหรือไม่ และตัดสินใจว่าจะยืนยัน (Confirm) หรือแก้ไข (Correct)

4) Output Constraint

กำหนดรูปแบบคำตอบให้ LLM ส่งกลับมาเป็นเพียง label เดียวเท่านั้น (“Reply with ONLY one label and nothing else”) เพื่อให้ง่ายต่อการนำไปประมวลผลต่อในระบบ และลดความกำกวมของผลลัพธ์ นอกจากนี้ยังมีกลไก Fallback โดยหากผลลัพธ์ที่ได้ไม่ตรงกับชุด Allowed Labels ระบบจะใช้ค่าที่ Baseline Model ทำนายไว้แทน

3.6 ขั้นตอนการไหลของข้อมูลและอัลกอริทึม (Data Workflow & Algorithm)

กระบวนการทำงานของ Hybrid Model ในแต่ละรอบของการทดสอบ (Inference) สามารถอธิบายเป็นลำดับขั้นตอนดังนี้

- ขั้นที่ 1 - Input: ระบบรับข้อความดิบ (Raw Text) และดำเนินการแปลงให้อยู่ในรูปแบบที่เหมาะสมกับแบบจำลอง โดยใช้ TF-IDF สำหรับกลุ่ม Machine Learning และใช้ Tokenization ร่วมกับ Padding สำหรับแบบจำลอง BiLSTM
- ขั้นที่ 2 - Base Prediction: ข้อมูลที่ผ่านการแปลงจะถูกส่งเข้าสู่แบบจำลองใน Tier 1 เพื่อทำการพยากรณ์ผลลัพธ์เบื้องต้น ($\hat{Y}_{base}$) พร้อมทั้งคำนวณค่าความเชื่อมั่น (C) จากค่าความน่าจะเป็นสูงสุดของแต่ละคลาส
- ขั้นที่ 3 - Threshold Check: ระบบนำค่า C ไปเปรียบเทียบกับค่าเกณฑ์ที่กำหนดไว้ที่ 0.70 เพื่อใช้เป็นเงื่อนไขในการเลือกเส้นทางการประมวลผล โดยหากค่าความเชื่อมั่นมีค่ามากกว่าหรือเท่ากับเกณฑ์ ระบบจะยอมรับผลลัพธ์ดังกล่าวทันที แต่หากต่ำกว่าเกณฑ์ ระบบจะเข้าสู่ขั้นตอนการปรับผลลัพธ์
- ขั้นที่ 4 - Refinement: ในกรณีที่ค่าความเชื่อมั่นต่ำ ระบบจะเรียกใช้ฟังก์ชัน เช่น llama_refine(), deepseek_refine() หรือ qwen_refine() เพื่อส่งข้อความและผลลัพธ์เดิมไปให้ LLM ทำการวิเคราะห์เพิ่มเติม และส่งกลับผลลัพธ์ใหม่ ($\hat{Y}_{AI}$) ที่เหมาะสมที่สุด
- ขั้นที่ 5 - Finalize: ระบบจะบันทึกผลลัพธ์ทั้งจาก Baseline Model และ Hybrid Model ลงในโครงสร้างข้อมูล (DataFrame) และส่งออกเป็นไฟล์เพื่อนำไปใช้ในการประเมินประสิทธิภาพของโมเดล โดยใช้ตัวชี้วัด เช่น Accuracy และ F1-Score

3.7 การประเมินและเปรียบเทียบประสิทธิภาพ

การประเมินผลในโครงการนี้ดำเนินการโดยใช้ชุดข้อมูลทดสอบ (Test Set) จำนวน 324 รายการ ซึ่งถูกแยกออกจากข้อมูลฝึกตั้งแต่ก่อนเริ่มกระบวนการฝึกโมเดล เพื่อป้องกันการรั่วไหลของข้อมูล (Data Leakage) และให้ผลการประเมินมีความน่าเชื่อถือ

ตัวชี้วัดที่ใช้ในการประเมินประกอบด้วย

- Accuracy: วัดสัดส่วนของจำนวนการทำนายที่ถูกต้องเมื่อเทียบกับจำนวนข้อมูลทั้งหมด
- F1-Score (Macro): ค่าเฉลี่ยของ F1-Score ในแต่ละคลาสโดยไม่ถ่วงน้ำหนัก ซึ่งเหมาะสมสำหรับชุดข้อมูลที่มีความไม่สมดุลระหว่างคลาส
- F1-Score (Weighted): ค่าเฉลี่ยของ F1-Score ที่มีการถ่วงน้ำหนักตามจำนวนตัวอย่างในแต่ละคลาส เพื่อสะท้อนประสิทธิภาพโดยรวมของโมเดล
- Classification Report (Per-class Precision, Recall, F1-Score): ใช้สำหรับวิเคราะห์ประสิทธิภาพในระดับรายคลาส เพื่อระบุจุดแข็งและจุดอ่อนของโมเดลในแต่ละประเภทของอารมณ์

บทที่ 4


ผลการดำเนินโครงการ

4.1 ผลลัพธ์ของ Machine Learning

ในการทดลองนี้ได้ทำการประเมินประสิทธิภาพของโมเดล Machine Learning จำนวน 4 โมเดล ได้แก่ Naive Bayes, Logistic Regression, Random Forest และ Support Vector Machine (SVM) สำหรับการจำแนกอารมณ์จากข้อความ โดยใช้ชุดข้อมูลทดสอบ (Test set) เป็นหลักในการรายงานผล เพื่อสะท้อนประสิทธิภาพของโมเดลในการใช้งานจริงอย่างเป็นกลาง

4.1.1 การวิเคราะห์แนวโน้มการเรียนรู้ของโมเดล


1) Naive Bayes



รูปที่ 4.1-1 แนวโน้มค่า Loss และ Accuracy ของโมเดล Naive Bayes

จากรูปที่ 4.1-1 พบว่า Training Loss และ Validation Loss ลดลงอย่างต่อเนื่อง ขณะที่ Validation Accuracy เพิ่มขึ้นอย่างสม่ำเสมอ แสดงให้เห็นว่าโมเดลสามารถเรียนรู้รูปแบบของข้อมูลได้ในระดับหนึ่ง อย่างไรก็ตาม ค่า Validation Accuracy ยังคงต่ำกว่า Training Accuracy อย่างต่อเนื่อง สะท้อนถึงข้อจำกัดของโมเดลในการจัดการข้อความที่มีความกำกวมหรือมีบริบทซับซ้อน โดยเฉพาะในคลาส fear และ neutral


2) Logistic Regression



รูปที่ 4.1-2 แนวโน้มค่า Loss และ Accuracy ของโมเดล Logistic Regression

จากรูปที่ 4.1-2 พบว่าโมเดลมีแนวโน้มการเรียนรู้ที่เสถียร โดยค่า Loss ของทั้งชุด Training และ Validation ลดลงอย่างต่อเนื่อง ขณะที่ Accuracy ของ Validation เพิ่มขึ้นและมีความใกล้เคียงกับ Training Accuracy มากกว่า Naive Bayes แสดงให้เห็นว่าโมเดลสามารถ generalize กับข้อมูลใหม่ได้ดี และไม่พบสัญญาณของ overfitting อย่างชัดเจน


3) Random Forest



รูปที่ 4.1-3 แนวโน้มค่า Loss และ Accuracy ของโมเดล Random Forest

จากรูปที่ 4.1-3 พบว่า Validation Accuracy เพิ่มขึ้นในระดับปานกลาง ขณะที่ Validation Loss ลดลงอย่างช้า ๆ และยังคงมีช่องว่างระหว่าง Training และ Validation อย่างต่อเนื่อง สะท้อนถึงความไม่สมดุลของโมเดลในการเรียนรู้ข้อมูลบางคลาส โดยเฉพาะคลาส neutral ซึ่งสอดคล้องกับผลการวิเคราะห์ Confusion Matrix ที่พบแนวโน้ม bias ไปยังคลาสดังกล่าว

4) Support Vector Machine (SVM)



รูปที่ 4.1-4 แนวโน้มค่า Loss และ Accuracy ของโมเดล Support Vector Machine (SVM)

จากรูปที่ 4.1-4 พบว่าโมเดล SVM มีแนวโน้มการเรียนรู้ที่ดีที่สุดในกลุ่ม Machine Learning โดยค่า Validation Accuracy เพิ่มขึ้นอย่างต่อเนื่องและมีความใกล้เคียงกับ Training Accuracy ขณะที่ค่า Loss ลดลงอย่างสม่ำเสมอ แสดงถึงความสามารถในการเรียนรู้และการ generalize ที่มีประสิทธิภาพ รวมถึงไม่พบสัญญาณของ overfitting อย่างชัดเจน ส่งผลให้โมเดลสามารถจัดการข้อมูลที่มีความกำกวมได้ดีกว่าโมเดลอื่น

สรุปผลการวิเคราะห์แนวโน้มการเรียนรู้

จากการวิเคราะห์แนวโน้มของค่า Loss และ Accuracy พบว่า Support Vector Machine (SVM) เป็นโมเดลที่มีความเสถียรและมีประสิทธิภาพในการเรียนรู้ที่ดีที่สุด โดยสามารถรักษาสอดคล้องระหว่าง Training และ Validation ได้อย่างเหมาะสม ขณะที่ Logistic Regression ให้ผลลัพธ์ในระดับดีและมี

แนวโน้มการเรียนรู้ที่สม่ำเสมอ ส่วน Naive Bayes และ Random Forest ยังมีข้อจำกัดในการจัดการข้อมูลที่มีความกำกวม ส่งผลให้ประสิทธิภาพของ Validation ต่ำกว่าโมเดลอื่นในบางช่วงการเรียนรู้

4.1.2 ผลการประเมินประสิทธิภาพโดยรวม

ตารางที่ 4.1-1 ผลการประเมินประสิทธิภาพของโมเดล Machine Learning (Test Set)

โมเดล	Accuracy	F1-Macro	F1-Weighted	Precision Macro	Precision Weighted
Naive Bayes	0.8920	0.9095	0.8920	0.9156	0.8954
Logistic Regression	0.9012	0.9173	0.9013	0.9188	0.9015
Random Forest	0.8549	0.8784	0.8553	0.9113	0.8858
Support Vector Machine (SVM)	0.9136	0.9276	0.9137	0.9297	0.9141

จากนิพจน์! ไม่พบแหล่งอ้างอิง พบว่า Support Vector Machine (SVM) เป็นโมเดลที่ให้ประสิทธิภาพสูงสุดในภาพรวม โดยมีค่า Accuracy เท่ากับ 0.91 และ F1-Macro เท่ากับ 0.93 รองลงมาคือ Logistic Regression ซึ่งให้ผลลัพธ์อยู่ในระดับดีและมีความสมดุลของค่า Precision และ F1-score ขณะที่ Naive Bayes ให้ผลลัพธ์ในระดับปานกลาง โดยยังมีข้อจำกัดในการจัดการข้อมูลที่มีความกำกวม ส่วน Random Forest เป็นโมเดลที่ให้ผลลัพธ์ต่ำที่สุดเมื่อเทียบกับโมเดลอื่น โดยเฉพาะค่า Accuracy และ F1-score ที่ลดลงอย่างชัดเจน

4.1.3 การวิเคราะห์ผลในระดับรายคลาส

1) Naive Bayes

ตารางที่ 4.1-2 ผลการประเมินในระดับรายคลาสของโมเดล Naive Bayes (Test Set)

Class	Precision	Recall	F1-score
angry	1.00	1.00	1.00
disgust	0.89	0.89	0.89
fear	0.86	0.73	0.79
happy	1.00	0.97	0.99
neutral	0.76	0.87	0.81
sad	0.98	0.98	0.98

โมเดลสามารถจำแนกคลาส angry, happy และ sad ได้ดี โดยมีค่า F1-score อยู่ในระดับสูง อย่างไรก็ตาม โมเดลยังมีข้อจำกัดในคลาส fear ซึ่งมีค่า recall เท่ากับ 0.73 และคลาส neutral ที่มีค่า F1-score เท่ากับ 0.81 สะท้อนถึงความยากในการจัดการข้อความที่มีลักษณะกำกวมหรือมีบริบทใกล้เคียงกัน

2) Logistic Regression

ตารางที่ 4.1-3 ผลการประเมินในระดับรายคลาสของโมเดล Logistic Regression (Test Set)

Class	Precision	Recall	F1-score
angry	0.98	1.00	0.99
disgust	0.86	0.78	0.82
fear	1.00	0.60	0.75
happy	1.00	0.97	0.99
neutral	0.65	0.92	0.76
sad	0.97	0.95	0.96

โมเดลให้ผลลัพธ์ที่มีความสมดุลมากขึ้น โดยสามารถจำแนกคลาสหลักได้อย่างแม่นยำ และมีประสิทธิภาพในการจัดการคลาส neutral ดีกว่า Naive Bayes ขณะที่คลาส fear ยังคงเป็นคลาสที่มีความท้าทายสำหรับโมเดล แม้ว่าค่า F1-score จะเพิ่มขึ้นเป็น 0.81 ก็ตาม

3) Random Forest

ตารางที่ 4.1-4 ผลการประเมินในระดับรายคลาสของโมเดล Random Forest (Test Set)

Class	Precision	Recall	F1-score
angry	1.00	1.00	1.00
disgust	0.87	0.83	0.85
fear	0.98	0.68	0.80
happy	1.00	0.97	0.99
neutral	0.70	0.92	0.80
sad	0.97	0.95	0.96

แม้ว่าโมเดลจะมีค่า precision สูงในบางคลาส แต่ผลลัพธ์โดยรวมยังมีความไม่สมดุล โดยเฉพาะคลาส neutral ที่มี recall สูงถึง 0.92 แต่มี precision เพียง 0.65 แสดงถึงแนวโน้ม bias ไปยังคลาสดังกล่าว นอกจากนี้ คลาส fear ยังมี recall ต่ำที่สุดในกลุ่มโมเดลทั้งหมด ส่งผลให้ค่า F1-score ลดลง และกระทบต่อประสิทธิภาพโดยรวมของโมเดล

4) Support Vector Machine (SVM)

ตารางที่ 4.1-5 ผลการประเมินในระดับรายคลาสของโมเดล Support Vector Machine (SVM) (Test Set)


Class	Precision	Recall	F1-score
angry	1.00	1.00	1.00
disgust	0.89	0.92	0.91
fear	0.88	0.83	0.85
happy	1.00	0.97	0.99
neutral	0.83	0.85	0.84
sad	0.98	0.98	0.98

โมเดล SVM เป็นโมเดลที่ให้ผลลัพธ์ที่ดีที่สุดในภาพรวม โดยมีความสมดุลระหว่าง precision และ recall ในทุกคลาส โดยเฉพาะคลาส fear และ neutral ที่มีค่า F1-score สูงกว่าโมเดลอื่น สะท้อนถึงความสามารถในการจัดการข้อมูลที่มีความกำกวมและลดความคลาดเคลื่อนในการจำแนกอารมณ์ได้อย่างมีประสิทธิภาพ

ผลวิเคราะห์ในระดับรายคลาส

- คลาส angry, happy และ sad สามารถจำแนกได้ดีในทุกโมเดล โดยมีค่า F1-score อยู่ในระดับสูง
- คลาส disgust มีประสิทธิภาพอยู่ในระดับดี แต่ยังพบความคลาดเคลื่อนในบางกรณี
- คลาส fear เป็นคลาสที่มีความท้าทายสูงที่สุด โดยมีค่า recall ต่ำกว่าคลาสอื่นในหลายโมเดล ส่งผลให้ค่า F1-score ลดลง
- คลาส neutral มีลักษณะกำกวมและเกิดความสับสนกับหลายคลาส โดยเฉพาะในโมเดล Random Forest ที่มีแนวโน้ม bias ไปยังคลาสดังกล่าว ส่งผลให้ค่า precision ลดลงเมื่อเทียบกับโมเดลอื่น

4.1.4 การวิเคราะห์ผลเชิงภาพ



รูปที่ 4.1-5 จำนวนการทำนายที่ถูกต้องในแต่ละคลาสของโมเดล Machine Learning


จากรูปที่ 4.1-5 พบว่าโมเดลทุกตัวสามารถจำแนกคลาส angry, happy และ sad ได้ดีและให้ผลลัพธ์ใกล้เคียงกัน ขณะที่คลาส fear และ neutral มีความท้าทายมากกว่า โดย Support Vector Machine (SVM) และ Logistic Regression ให้ผลลัพธ์ที่ดีที่สุดในคลาสดังกล่าว ส่วน Random Forest แม้จะทำนายคลาส neutral ได้ถูกต้องจำนวนมาก แต่มีแนวโน้ม bias ไปยังคลาสนี้ ส่งผลให้ค่า

precision ลดลง โดยภาพรวม SVM เป็นโมเดลที่มีประสิทธิภาพดีที่สุด เนื่องจากสามารถรักษาสมดุลของผลลัพธ์ในแต่ละคลาสได้ดีและมีความคลาดเคลื่อนต่ำกว่าโมเดลอื่น

4.2 ผลลัพธ์ของ Deep Learning

ในการทดลองนี้ได้ทำการประเมินประสิทธิภาพของโมเดล Deep Learning (BiLSTM) สำหรับการจำแนกอารมณ์จากข้อความ โดยใช้ชุดข้อมูลทดสอบ (Test set) เพื่อสะท้อนประสิทธิภาพในการใช้งานจริง

4.2.1 การวิเคราะห์แนวโน้มการเรียนรู้ของโมเดล



รูปที่ 4.2-1 แนวโน้มค่า Loss และ Accuracy ของโมเดล BiLSTM

จากรูปที่ 4.2-1 พบว่าโมเดล BiLSTM สามารถเรียนรู้ข้อมูลได้ดี โดยค่า Training Loss และ Validation Loss ลดลงอย่างต่อเนื่อง ขณะที่ Accuracy เพิ่มขึ้นและคงที่อยู่ในระดับสูง สะท้อนถึงความสามารถในการจำแนกข้อมูลได้อย่างมีประสิทธิภาพ อย่างไรก็ตาม ในช่วงท้ายของการฝึกพบว่า Validation Loss เพิ่มขึ้นเล็กน้อย ขณะที่ Training Accuracy ยังคงเพิ่มขึ้น ซึ่งอาจบ่งชี้ถึงแนวโน้มการเกิด overfitting ในบางช่วงของการเรียนรู้

4.2.2 ผลการประเมินประสิทธิภาพโดยรวม

ตารางที่ 4.2-1 ผลการประเมินประสิทธิภาพของโมเดล Deep Learning (Test Set)

Accuracy	F1-Macro	F1-Weighted	Precision Macro	Precision Weighted
0.9043	0.9170	0.9029	0.9182	0.9046

จากรูปที่ 4.2-1 พบว่าโมเดล Deep Learning (BiLSTM) มีค่า Accuracy เท่ากับ 0.90 และ F1-Macro เท่ากับ 0.92 ซึ่งอยู่ในระดับดี แสดงถึงความสามารถในการจำแนกอารมณ์จากข้อความได้อย่างมีประสิทธิภาพ และมีความสมดุลของผลลัพธ์ในภาพรวม โดยเฉพาะคลาสที่มีลักษณะข้อมูลชัดเจน เช่น angry, disgust และ sad ที่ให้ค่า F1-score อยู่ในระดับสูง ขณะที่คลาส fear และ neutral ยังคงเป็นคลาสที่มีความท้าทายในการจำแนก เนื่องจากมีลักษณะข้อมูลที่กำกวมและใกล้เคียงกับหลายอารมณ์

4.2.3 การวิเคราะห์ผลในระดับรายคลาส

เมื่อพิจารณาผลจาก Classification Report สามารถสรุปผลในระดับรายคลาสได้ดังตารางต่อไปนี้


ตารางที่ 4.2-2 ตารางที่ 4.x ผลการประเมินในระดับรายคลาสของโมเดล Deep Learning (Test Set)

Class	Precision	Recall	F1-score
angry	0.96	1.00	0.98
disgust	0.92	0.95	0.94
fear	0.88	0.73	0.80
happy	0.94	0.97	0.96
neutral	0.80	0.85	0.83
sad	1.00	1.00	1.00

ผลวิเคราะห์ในระดับรายคลาส

- คลาส angry, disgust และ sad สามารถจำแนกได้ดี โดยมีค่า F1-score อยู่ในระดับสูง
- คลาส happy ให้ผลลัพธ์อยู่ในระดับดีและมีความแม่นยำสูง
- คลาส fear เป็นคลาสที่มีความท้าทายมากที่สุด โดยมีค่า recall ต่ำ ส่งผลให้ค่า F1-score ต่ำกว่าคลาสอื่น
- คลาส neutral มีลักษณะข้อมูลที่กำกวม ทำให้เกิดความสับสนกับหลายคลาสและส่งผลต่อประสิทธิภาพในการจำแนกบางส่วน

4.2.4 การวิเคราะห์ผลเชิงภาพ



รูปที่ 4.2-2 จำนวนการทำนายที่ถูกต้องในแต่ละคลาสของโมเดล Deep Learning

จากรูปที่ 4.2-2 พบว่าโมเดล Deep Learning สามารถจำแนกคลาส angry, disgust และ sad ได้ดี โดยมีจำนวนการทำนายถูกในระดับสูง ขณะที่คลาส fear มีจำนวนการทำนายถูกต่ำกว่าคลาสอื่น สะท้อนถึงความยากในการจำแนกอารมณ์ที่มีลักษณะใกล้เคียงกับหลายคลาส ส่วนคลาส neutral แม้จะมีจำนวนการทำนายถูกสูง แต่ยังคงเกิดความสับสนกับบางคลาสในบางกรณี โดยภาพรวมโมเดลสามารถจำแนกอารมณ์ได้อย่างมีประสิทธิภาพและให้ผลลัพธ์สอดคล้องกับค่าประเมินใน Classification Report

4.3 ผลลัพธ์ของ Hybrid Model

การทดลองในส่วนนี้เป็นการประเมินประสิทธิภาพของ Hybrid Model โดยผสมการทำงานระหว่างโมเดล Machine Learning ได้แก่ Naive Bayes, Logistic Regression, Random Forest และ Support Vector Machine รวมถึงโมเดล Deep Learning คือ BiLSTM ร่วมกับ Large Language Model (LLM) จำนวน 3 โมเดล ได้แก่ Llama3.1:8b, DeepSeek-R1:8B และ Qwen 2.5:7B-Instruct

โดย LLM ทำหน้าที่ปรับแก้ผลการทำนายในกรณีที่โมเดลหลักมีค่าความเชื่อมั่นต่ำกว่า 0.70 ร่วมกับแนวทาง Few-shot In-Context Learning ทั้งนี้ผลลัพธ์ของโมเดลพื้นฐาน (baseline) สามารถอ้างอิงได้จากหัวข้อ 4.1 และ 4.2

การทดลองในส่วนนี้มีวัตถุประสงค์เพื่อประเมินว่าแนวทาง Hybrid Model ซึ่งผสานการทำงานระหว่างโมเดล Machine Learning, Deep Learning และ Large Language Model (LLM) สามารถช่วยปรับปรุงประสิทธิภาพในการจำแนกอารมณ์จากข้อความได้หรือไม่ โดย LLM จะถูกนำมาใช้ในกรณีที่โมเดลหลักมีค่าความเชื่อมั่นต่ำ เพื่อช่วยตัดสินใจในตัวอย่างที่มีความกำกวม

จากผลการทดลองพบว่าประสิทธิภาพของ Hybrid Model มีความแตกต่างกันอย่างชัดเจนขึ้นอยู่กับ LLM ที่เลือกใช้ โดยแต่ละโมเดลให้ผลลัพธ์และพฤติกรรมที่แตกต่างกัน ดังนี้

4.3.1 ผลการประเมินประสิทธิภาพโดยรวมของ Llama3.1:8b

ในการทดลองนี้ได้ทำการประเมินประสิทธิภาพของ Hybrid Model ซึ่งผสานการทำงานระหว่างโมเดล Machine Learning และ Deep Learning ร่วมกับ Large Language Model (LLM) ได้แก่ Llama 3.1:8B โดย LLM ถูกนำมาใช้เพื่อปรับแก้ผลการทำนายในกรณีที่โมเดลหลักมีค่าความเชื่อมั่นต่ำ

ตารางที่ 4.3-1 ผลการประเมินประสิทธิภาพของ Hybrid Model (Llama 3.1:8B) (Test Set)

โมเดล	Accuracy	F1-Macro	F1-Weighted	Precision Macro	Precision Weighted
Naive Bayes + Llama 3.1:8B	0.8117	0.8175	0.8158	0.8395	0.8713
Logistic Regression + Llama 3.1:8B	0.7809	0.7883	0.7868	0.8243	0.8610
Random Forest + Llama 3.1:8B	0.7130	0.7229	0.7166	0.7997	0.8453
SVM + Llama 3.1:8B	0.8827	0.8840	0.8824	0.8804	0.8988
BiLSTM + Llama 3.1:8B	0.8673	0.8689	0.8658	0.8657	0.8810

จากตารางพบว่า SVM + Llama 3.1:8B ให้ผลลัพธ์ที่ดีที่สุดในกลุ่ม Machine Learning Hybrid ขณะที่ BiLSTM + Llama มีค่า Accuracy อยู่ในระดับสูง แต่ค่า F1-Macro ลดลงเมื่อเทียบกับ baseline แสดงถึงความไม่สมดุลของผลลัพธ์

4.3.1.1 การวิเคราะห์ผลในระดับรายคลาส

- **Naive Bayes + Llama 3.1:8B**

ประสิทธิภาพลดลงจาก baseline และเกิดความไม่สมดุลในหลายคลาส โดย angry ยังคงแม่นยำสูง (F1 = 0.97) ขณะที่ neutral (recall = 0.61) และ disgust (0.75) ลดลง นอกจากนี้ happy และ sad มี recall สูงแต่ precision ต่ำ สะท้อนปัญหา over-prediction

ตารางที่ 4.3-2 ผลการประเมินในระดับรายคลาสของโมเดล Naive Bayes + Llama 3.1:8B (Test Set)

Class	Precision	Recall	F1-score
angry	0.94	1.00	0.97
disgust	0.98	0.75	0.85
fear	0.92	0.73	0.81
happy	0.71	1.00	0.83
neutral	0.96	0.61	0.75
sad	0.53	1.00	0.69

- **Logistic Regression + Llama 3.1:8B**

โมเดลมีประสิทธิภาพลดลงมากที่สุด โดยเฉพาะ neutral (recall = 0.53) ขณะที่ happy และ sad มี recall สูงแต่ precision ต่ำ แสดงถึงการทำนายเกิน ส่งผลให้ความสมดุลลดลง

ตารางที่ 4.3-3 ผลการประเมินในระดับรายคลาสของโมเดล Logistic Regression + Llama 3.1:8B (Test Set)

Class	Precision	Recall	F1-score
angry	0.92	0.90	0.91
disgust	1.00	0.72	0.84

fear	0.92	0.78	0.85
happy	0.67	1.00	0.80
neutral	0.95	0.53	0.68
sad	0.48	1.00	0.65

- **Random Forest + Llama 3.1:8B**

เกิดความไม่สมดุลชัดเจน โดย neutral (recall = 0.36) ต่ำมาก ขณะที่ happy และ sad มี recall สูงแต่ precision ต่ำ นอกจากนี้ fear มี precision สูงแต่ recall ต่ำ ส่งผลให้ประสิทธิภาพลดลง

ตารางที่ 4.3-4 ผลการประเมินในระดับรายคลาสของโมเดล Random Forest + Llama 3.1:8B (Test Set)

Class	Precision	Recall	F1-score
angry	0.92	0.90	0.91
disgust	1.00	0.67	0.80
fear	0.98	0.68	0.80
happy	0.56	1.00	0.72
neutral	0.93	0.36	0.52
sad	0.41	1.00	0.58

- **Support Vector Machine + Llama 3.1:8B**

เป็นโมเดลที่ดีที่สุดในกลุ่ม ML Hybrid โดยยังคงความสมดุลได้ดีกว่าโมเดลอื่น อย่างไรก็ตาม happy และ sad มี recall สูงแต่ precision ลดลง และ neutral (recall = 0.75) ยังมีความคลาดเคลื่อน

ตารางที่ 4.3-5 ผลการประเมินในระดับรายคลาสของโมเดล Support Vector Machine + Llama 3.1:8B (Test Set)

Class	Precision	Recall	F1-score
angry	0.94	1.00	0.97
disgust	0.98	0.91	0.94
fear	0.92	0.78	0.85
happy	0.80	1.00	0.89
neutral	0.93	0.75	0.83
sad	0.71	1.00	0.83

- BiLSTM + Llama 3.1:8B


แม้ Accuracy ยังอยู่ในระดับดี แต่ F1-Macro ลดลง สะท้อนความไม่สมดุล โดย fear (recall = 0.70) และ neutral (0.75) ยังเป็นจุดอ่อน ขณะที่ happy และ sad มี recall สูงแต่ precision ต่ำ

ตารางที่ 4.3-6 ผลการประเมินในระดับรายคลาสของโมเดล BiLSTM + Llama 3.1:8B (Test Set)

Class	Precision	Recall	F1-score
angry	0.96	1.00	0.98
disgust	0.95	0.92	0.94
fear	0.89	0.70	0.79
happy	0.80	1.00	0.89
neutral	0.90	0.75	0.82
sad	0.69	0.98	0.81


- คลาส angry ยังคงมีความแม่นยำสูงในทุกโมเดล
- คลาส fear และ neutral เป็นคลาสที่มีความท้าทาย โดยมีค่า recall ลดลงในหลายโมเดล
- คลาส happy และ sad มีแนวโน้ม recall สูง แต่ precision ต่ำ สะท้อนปัญหา over-prediction
- โมเดลส่วนใหญ่เกิดความไม่สมดุลของผลลัพธ์ โดยเฉพาะการสับสนระหว่าง neutral กับคลาสอื่น
- โดยรวม Hybrid Model ที่ใช้ Llama 3.1:8B ทำให้ประสิทธิภาพลดลงและผลลัพธ์มีความไม่สมดุลเมื่อเทียบกับ baseline

4.3.1.2 การวิเคราะห์ผลเชิงภาพ



รูปที่ 4.3-1 แสดงจำนวนการทำนายถูกของแต่ละโมเดล Hybrid (Machine Learning ร่วมกับ Llama 3.1:8B)

ผลการทดลองแสดงให้เห็นว่าในคลาส angry, happy และ sad โมเดลให้ผลลัพธ์ใกล้เคียงกัน แสดงถึงความสามารถในการจำแนกคลาสที่มีลักษณะชัดเจนได้ดี ขณะที่คลาส disgust และ neutral มีความแตกต่างระหว่างโมเดลอย่างชัดเจน โดย SVM ให้ผลดีที่สุด ส่วน Random Forest ให้ผลต่ำสุดในคลาส neutral สะท้อนถึงความไม่สมดุลของโมเดล นอกจากนี้คลาส fear ให้ผลใกล้เคียงกันทุกโมเดลและไม่ปรับปรุงขึ้นอย่างชัดเจน แสดงถึงความยากในการจำแนกของคลาสนี้



รูปที่ 4.3-2 จำนวนการทำนายถูกในแต่ละคลาสของโมเดล Hybrid (Deep Learning (BiLSTM) ร่วมกับ Llama 3.1:8B)

ผลการทดลองแสดงให้เห็นว่าโมเดล Deep Learning ร่วมกับ Llama 3.1:8B สามารถจำแนกคลาส angry (49), disgust (59), neutral (56) และ sad (40) ได้ในระดับสูง ขณะที่คลาส fear (42) ให้ผลลัพธ์ลดลง และคลาส happy (35) มีจำนวนการทำนายถูกต่ำที่สุดเมื่อเทียบกับคลาสอื่น สะท้อนถึงข้อจำกัดของโมเดลในการจำแนกคลาสที่มีความกำกวมหรือมีลักษณะใกล้เคียงกัน

สรุปผล (Conclusion)

โดยภาพรวม Hybrid Model ที่ใช้ Llama 3.1:8B ไม่สามารถปรับปรุงประสิทธิภาพของโมเดลได้ และมีแนวโน้มทำให้ผลลัพธ์ลดลงเมื่อเทียบกับ baseline เนื่องจากการปรับแก้ผลลัพธ์ของ LLM ทำให้เกิดความไม่สมดุล โดยเฉพาะในคลาสที่มีความกำกวม เช่น neutral และ fear รวมถึงพบปัญหา over-prediction ในบางคลาส ส่งผลให้ความแม่นยำโดยรวมลดลง

4.3.2 ผลการประเมินประสิทธิภาพโดยรวม DeepSeek-R1:8B

ในการทดลองนี้ได้ประเมิน Hybrid Model โดยผสานโมเดล Machine Learning และ Deep Learning ร่วมกับ Large Language Model ได้แก่ DeepSeek-R1:8B ซึ่งถูกนำมาใช้เพื่อปรับแก้ผลการทำนายในกรณีที่โมเดลหลักมีค่าความเชื่อมั่นต่ำ

ตารางที่ 4.3-7 ผลการประเมินประสิทธิภาพของ Hybrid Model (DeepSeek-R1:8B) (Test Set)

โมเดล	Accuracy	F1-Macro	F1-Weighted	Precision Macro	Precision Weighted
Naive Bayes + DeepSeek-R1:8B	0.9043	0.9095	0.9034	0.9058	0.9079
Logistic Regression + DeepSeek-R1:8B	0.8920	0.8962	0.8919	0.8964	0.9017
Random Forest + DeepSeek-R1:8B	0.8827	0.8887	0.8824	0.8917	0.8945
SVM + DeepSeek-R1:8B	0.9074	0.9160	0.9061	0.9142	0.9101
BiLSTM + DeepSeek-R1:8B	0.9074	0.9137	0.9056	0.9108	0.9077

4.3.2.1 การวิเคราะห์ผลในระดับรายคลาส

- Naive Bayes + DeepSeek-R1:8B

โมเดลมีประสิทธิภาพดีขึ้นจาก baseline โดยเฉพาะคลาส neutral (recall = 0.87) และ fear (0.78) ขณะที่คลาส happy และ sad ยังคงมี recall สูงโดยไม่เกิดปัญหา precision ต่ำรุนแรง ส่งผลให้ความสมดุลของผลลัพธ์โดยรวมดีขึ้น

ตารางที่ 4.3-8 ผลการประเมินในระดับรายคลาสของโมเดล Naive Bayes + DeepSeek-R1:8B (Test Set)

Class	Precision	Recall	F1-score
angry	0.94	1.00	0.97
disgust	0.97	0.89	0.93
fear	0.94	0.78	0.85
happy	0.83	1.00	0.91
neutral	0.84	0.87	0.86
sad	0.91	0.98	0.94

- Logistic Regression + DeepSeek-R1:8B

โมเดลมีความสมดุลของผลลัพธ์ดีขึ้น โดยคลาส neutral (recall = 0.88) และ fear (0.77) มีการปรับปรุง ขณะที่คลาส happy และ sad มี recall สูงโดยไม่เกิด over-prediction ส่งผลให้ค่า F1-score มีความสม่ำเสมอมากขึ้น

ตารางที่ 4.3-9 ผลการประเมินในระดับรายคลาสของโมเดล Logistic Regression + DeepSeek-R1:8B (Test Set)

Class	Precision	Recall	F1-score
angry	0.94	0.92	0.93
disgust	1.00	0.88	0.93
fear	0.96	0.77	0.85
happy	0.85	1.00	0.92
neutral	0.82	0.88	0.85
sad	0.80	1.00	0.89

- Random Forest + DeepSeek-R1:8B

โมเดลมีการปรับปรุงจาก baseline โดยคลาส neutral (recall = 0.89) เพิ่มขึ้น ช่วยลด bias เดิม อย่างไรก็ตามคลาส fear (recall = 0.75) ยังคงเป็นข้อจำกัดหลักของโมเดล

ตารางที่ 4.3-10 ผลการประเมินในระดับรายคลาสของโมเดล Random Forest + DeepSeek-R1:8B (Test Set)

Class	Precision	Recall	F1-score
angry	0.96	0.92	0.94
disgust	1.00	0.83	0.91
fear	0.94	0.75	0.83
happy	0.85	1.00	0.92
neutral	0.80	0.89	0.84
sad	0.80	1.00	0.89

- Support Vector Machine + DeepSeek-R1:8B

โมเดลมีความสมดุลของ precision และ recall ในทุกคลาส โดยเฉพาะคลาส neutral (recall = 0.87) และ fear (0.75) ที่อยู่ในระดับดี สะท้อนถึงความสามารถในการจัดการข้อมูลที่มีความกำกวมได้อย่างมีประสิทธิภาพ

ตารางที่ 4.3-11 ผลการประเมินในระดับรายคลาสของโมเดล Support Vector Machine + DeepSeek-R1:8B (Test Set)

Class	Precision	Recall	F1-score
angry	0.94	1.00	0.97
disgust	0.98	0.92	0.95
fear	0.92	0.75	0.83
happy	0.88	1.00	0.93
neutral	0.81	0.87	0.84
sad	0.95	1.00	0.98

- BiLSTM + DeepSeek-R1:8B

โมเดล Deep Learning มีการปรับปรุงเล็กน้อยจาก baseline โดยคลาส neutral (recall = 0.89) ดีขึ้น ขณะที่คลาส fear (0.73) ยังคงเป็นจุดที่ท้าทาย แม้ภาพรวมยังคงมีความสมดุลในระดับดี


Class	Precision	Recall	F1-score
angry	0.98	1.00	0.99
disgust	0.95	0.92	0.94
fear	0.88	0.73	0.80
happy	0.88	1.00	0.93
neutral	0.85	0.89	0.87
sad	0.93	0.98	0.95

ตารางที่ 4.x ผลการประเมินในระดับรายคลาสของโมเดล BiLSTM + DeepSeek-R1:8B (Test Set)

ผลวิเคราะห์ในระดับรายคลาส


- คลาส **angry** และ **happy** ยังคงมีความแม่นยำสูงในทุกโมเดล
- คลาส **neutral** มีการปรับปรุงอย่างชัดเจนเมื่อเทียบกับ baseline
- คลาส **fear** ยังคงเป็นคลาสที่มีความท้าทาย โดยมีค่า recall อยู่ในระดับปานกลาง
- ไม่พบปัญหา **over-prediction** อย่างมีนัยสำคัญ เมื่อเทียบกับ Llama 3.1:8B
- โดยรวมโมเดลมี **ความสมดุลของ precision และ recall ดีขึ้น** อย่างสม่ำเสมอ

4.3.2.2 การวิเคราะห์ผลเชิงภาพ



รูปที่ 4.3-3 แสดงจำนวนการทำนายถูกของแต่ละโมเดล Hybrid (Machine Learning DeepSeek-R1:8B)

ผลการทดลองแสดงให้เห็นว่าในคลาส angry และ sad โมเดลให้ผลลัพธ์สูงและใกล้เคียงกัน ขณะที่คลาส disgust และ fear มีแนวโน้มดีขึ้นเมื่อเทียบกับ baseline โดยเฉพาะในโมเดล Naive Bayes และ SVM สำหรับคลาส neutral ทุกโมเดลมีจำนวนการทำนายถูกอยู่ในระดับสูง (ประมาณ 65–67) สะท้อนถึงการลดความสับสนของคลาask้าวมาได้ดีขึ้น



รูปที่ 4.3-4 จำนวนการทำนายถูกในแต่ละคลาสของโมเดล Hybrid (Deep Learning (BiLSTM) ร่วมกับ DeepSeek-R1:8B)

โมเดลสามารถจำแนกคลาส angry, disgust และ neutral ได้ในระดับสูง โดยคลาส neutral มีจำนวนการทำนายถูกสูงสุด (67) ขณะที่คลาส happy และ sad อยู่ในระดับคงที่ และคลาส fear (44) ยังคงมีความท้าทาย แม้มีแนวโน้มดีขึ้นเมื่อเทียบกับ baseline

สรุปผล (Conclusion)

Hybrid Model ที่ใช้ DeepSeek-R1:8B สามารถปรับปรุงประสิทธิภาพของโมเดลได้ในภาพรวม โดยช่วยเพิ่มค่า Accuracy และ F1-Macro พร้อมทั้งลดความสับสนของคลาสที่มีความกำกวม โดยเฉพาะคลาส neutral อย่างชัดเจน ขณะเดียวกันไม่พบปัญหา over-prediction รุนแรงเหมือนใน Llama 3.1:8B ส่งผลให้ความสมดุลของ precision และ recall ดีขึ้น อย่างไรก็ตามตามคลาส fear ยังคงเป็นข้อจำกัดหลักของทุกโมเดล โดยมีค่า recall อยู่ในระดับปานกลาง ทำให้ยังคงเป็นคลาสที่ท้าทายในการจำแนก แม้ภาพรวมของโมเดลจะมีแนวโน้มดีขึ้นอย่างมีนัยสำคัญ

4.3.3 ผลการประเมินประสิทธิภาพโดยรวม Qwen 2.5:7B-Instruct

ในการทดลองนี้ได้ประเมิน Hybrid Model โดยผสานโมเดล Machine Learning และ Deep Learning ร่วมกับ Large Language Model ได้แก่ Qwen 2.5:7B-Instruct ซึ่งถูกใช้ในการปรับแก้ผลการทำนายในกรณีที่โมเดลมีความเชื่อมั่นต่ำ เพื่อเพิ่มความแม่นยำและความสมดุลของผลลัพธ์

ตารางที่ 4.3-12 ผลการประเมินประสิทธิภาพของ Hybrid Model (Qwen 2.5:7B-Instruct) (Test Set)

โมเดล	Accuracy	F1-Macro	F1-Weighted	Precision Macro	Precision Weighted
Naive Bayes + Qwen 2.5:7B-Instruct	0.9105	0.9182	0.9091	0.9199	0.9161
Logistic Regression + Qwen 2.5:7B-Instruct	0.8981	0.9072	0.8975	0.9116	0.9063
Random Forest + Qwen 2.5:7B-Instruct	0.8889	0.8966	0.8880	0.9045	0.9027
Support Vector Machine + Qwen 2.5:7B-Instruct	0.9167	0.9255	0.9154	0.9266	0.9198
BiLSTM + Qwen 2.5:7B-Instruct	0.9136	0.9203	0.9113	0.9213	0.9151

ผลการทดลองแสดงให้เห็นว่า Qwen 2.5:7B-Instruct สามารถปรับปรุงประสิทธิภาพของหลายโมเดลได้ โดยเฉพาะ Naive Bayes และ Random Forest ที่มีค่า Accuracy และ F1-Macro เพิ่มขึ้น ขณะที่ SVM และ BiLSTM ยังคงให้ผลลัพธ์สูงและมีความสมดุลของโมเดลโดยรวมดีที่สุด

4.3.3.1 การวิเคราะห์ผลในระดับรายคลาส

- Naive Bayes + Qwen 2.5:7B-Instruct

โมเดลมีการปรับปรุงจาก baseline อย่างชัดเจน โดยเฉพาะคลาส neutral และ disgust ที่มีค่า recall เพิ่มขึ้น ขณะที่คลาส happy และ sad ยังคงมี recall สูงโดยไม่เกิดปัญหา precision ต่ำ ส่งผลให้ความสมดุลของผลลัพธ์ดีขึ้นอย่างมีนัยสำคัญ

ตารางที่ 4.3-13 ผลการประเมินในระดับรายคลาสของโมเดล Naive Bayes + Qwen 2.5:7B-Instruct (Test Set)

Class	Precision	Recall	F1-score
angry	0.98	1.00	0.99
disgust	0.97	0.91	0.94
fear	0.96	0.73	0.83
happy	0.88	1.00	0.93
neutral	0.81	0.91	0.86
sad	0.93	1.00	0.96

- Logistic Regression + Qwen 2.5:7B-Instruct

โมเดลมีความสมดุลของผลลัพธ์ดีขึ้น โดยคลาส neutral มี recall เพิ่มขึ้น ขณะที่คลาส fear ยังคงอยู่ในระดับปานกลาง และคลาสหลักยังคงมีความแม่นยำสูงโดยไม่เกิด over-prediction

ตารางที่ 4.3-14 ผลการประเมินในระดับรายคลาสของโมเดล Logistic Regression + Qwen 2.5:7B-Instruct (Test Set)

Class	Precision	Recall	F1-score
angry	0.96	0.94	0.95
disgust	0.97	0.89	0.93
fear	0.96	0.73	0.83
happy	0.88	1.00	0.93
neutral	0.78	0.91	0.84
sad	0.93	1.00	0.96

ตารางที่ 4.x ผลการประเมินในระดับรายคลาสของโมเดล Logistic Regression + Qwen 2.5:7B-Instruct (Test Set)

- Random Forest + Qwen 2.5:7B-Instruct

โมเดลสามารถลด bias ในคลาส neutral ได้อย่างชัดเจนจากการเพิ่มค่า recall อย่างไรก็ตาม คลาส fear ยังคงเป็นข้อจำกัดหลัก แม้ภาพรวมของ precision และ recall จะมีความสมดุลมากขึ้น

Class	Precision	Recall	F1-score
angry	0.96	0.94	0.95
disgust	0.96	0.84	0.90
fear	1.00	0.72	0.83
happy	0.88	1.00	0.93
neutral	0.78	0.92	0.84
sad	0.85	1.00	0.92

ตารางที่ 4.x ผลการประเมินในระดับรายคลาสของโมเดล Random Forest + Qwen 2.5:7B-Instruct (Test Set)

- Support Vector Machine + Qwen 2.5:7B-Instruct

โมเดลมีความสมดุลของ precision และ recall ในทุกคลาส โดยเฉพาะคลาส neutral และ fear ที่อยู่ในระดับดี สะท้อนถึงความสามารถในการจัดการข้อมูลกำกวมได้อย่างมีประสิทธิภาพ

ตารางที่ 4.3-15 ผลการประเมินในระดับรายคลาสของโมเดล Support Vector Machine + Qwen 2.5:7B-Instruct (Test Set)

Class	Precision	Recall	F1-score
angry	0.96	1.00	0.98
disgust	0.97	0.92	0.94
fear	0.94	0.75	0.83
happy	0.92	1.00	0.96
neutral	0.82	0.91	0.86
sad	0.95	1.00	0.98

- BiLSTM + Qwen 2.5:7B-Instruct

โมเดล Deep Learning มีการปรับปรุงจาก baseline โดยคลาส neutral มี recall เพิ่มขึ้น ขณะที่คลาส fear ยังคงเป็นจุดที่ท้าทาย อย่างไรก็ตามภาพรวมยังคงมีความสมดุลของผลลัพธ์ในระดับดี


ตารางที่ 4.3-16 ผลการประเมินในระดับรายคลาสของโมเดล BiLSTM + Qwen 2.5:7B-Instruct (Test Set)

Class	Precision	Recall	F1-score
angry	0.96	1.00	0.98
disgust	0.94	0.94	0.94
fear	0.91	0.72	0.80
happy	0.90	1.00	0.95
neutral	0.84	0.92	0.88
sad	0.98	0.98	0.98

ผลวิเคราะห์ในระดับรายคลาส


- คลาส angry, happy และ sad ยังคงมีความแม่นยำสูงในทุกโมเดล
- คลาส neutral มีการปรับปรุงอย่างชัดเจน จาก baseline ในทุกโมเดล
- คลาส fear ยังคงเป็นคลาสที่มีความท้าทาย โดยมีค่า recall อยู่ในระดับปานกลาง
- ไม่พบปัญหา over-prediction อย่างมีนัยสำคัญ เมื่อเทียบกับ Llama 3.1:8B
- โดยรวม Hybrid Model ที่ใช้ Qwen 2.5:7B-Instruct ให้ประสิทธิภาพสูงสุด ทั้งในด้านความแม่นยำและความสมดุลของผลลัพธ์

4.3.3.2 การวิเคราะห์ผลเชิงภาพ



รูปที่ 4.3-5 แสดงจำนวนการทำนายถูกของแต่ละโมเดล Hybrid (Machine Learning Qwen 2.5:7B-Instruct)

ผลการทดลองแสดงให้เห็นว่าในคลาส angry และ sad โมเดลให้ผลลัพธ์ใกล้เคียงกันทุกโมเดล ขณะที่คลาส happy มีจำนวนการทำนายถูกเท่ากันทั้งหมด (35) แสดงถึงความสม่ำเสมอของผลลัพธ์ ในคลาส disgust และ fear พบว่า SVM ให้ผลลัพธ์ดีที่สุด โดยมีจำนวนการทำนายถูกสูงสุดเมื่อเทียบกับโมเดลอื่น ส่วนคลาส neutral ทุกโมเดลมีจำนวนการทำนายถูกในระดับสูง (ประมาณ 68–69) และมีความแตกต่างกันเพียงเล็กน้อย สะท้อนถึงความสามารถของ Qwen ในการลดความกำกวมของข้อมูลได้อย่างมีประสิทธิภาพ



รูปที่ 4.3-6 จำนวนการทำนายถูกในแต่ละคลาสของโมเดล Hybrid (Deep Learning (BiLSTM) ร่วมกับ Qwen 2.5:7B-Instruct)

โมเดลสามารถจำแนกคลาส angry (49), disgust (60), neutral (69) และ sad (40) ได้ในระดับสูง โดยคลาส neutral มีจำนวนการทำนายถูกสูงสุด ขณะที่คลาส happy มีจำนวนการทำนายถูกค้งที่ (35) และคลาส fear (43) ยังคงมีจำนวนการทำนายถูกต่ำกว่าคลาสอื่น สะท้อนถึงความท้าทายในการจำแนกอารมณ์ที่มีความกำกวม แม้ภาพรวมของผลลัพธ์จะอยู่ในระดับดี

สรุปผล (Conclusion)

Hybrid Model ที่ใช้ Qwen 2.5:7B-Instruct ให้ประสิทธิภาพสูงสุดเมื่อเทียบกับแนวทางอื่น โดยสามารถปรับปรุงทั้ง Accuracy และ F1-Macro ได้อย่างสม่ำเสมอในทุกโมเดล อีกทั้งยังช่วยลดความคลาดเคลื่อนในคลาสที่มีความกำกวม เช่น neutral และ fear ส่งผลให้ความสมดุลของผลลัพธ์โดยรวมดีขึ้นอย่างชัดเจน และมีประสิทธิภาพเหนือกว่า DeepSeek-R1:8B และ Llama 3.1:8B อย่างมีนัยสำคัญ

4.4 การเปรียบเทียบผล

หัวข้อนี้เป็นการเปรียบเทียบประสิทธิภาพของโมเดลพื้นฐาน (Machine Learning และ Deep Learning) และ Hybrid Model ที่ใช้ LLM ได้แก่ Llama 3.1:8B, DeepSeek-R1:8B และ Qwen 2.5:7B-Instruct โดยพิจารณาจากค่า Test Accuracy, F1-Macro, F1-Weighted และ Total pipeline time เพื่อสะท้อนประสิทธิภาพในการใช้งานจริง

4.4.1 การเปรียบเทียบโมเดลพื้นฐาน

ตารางที่ 4.4-1 การเปรียบเทียบประสิทธิภาพของโมเดลพื้นฐาน

โมเดล	Accuracy	F1-Macro	F1-Weighted	Total pipeline time
Naive Bayes	0.89	0.91	0.89	3.15s
Logistic Regression	0.90	0.92	0.90	3.15 s
Random Forest	0.85	0.88	0.86	3.15 s
Support Vector Machine (SVM)	0.91	0.93	0.91	3.15 s
BiLSTM	0.90	0.92	0.90	12.35 s

จากผลการทดลองพบว่า Support Vector Machine (SVM) เป็นโมเดลที่ให้ประสิทธิภาพดีที่สุด ในภาพรวม โดยมีค่า Accuracy และ F1-Macro สูงที่สุดในกลุ่มโมเดลพื้นฐาน สะท้อนถึงความสามารถในการจำแนกข้อมูลที่มีความกำกวมได้อย่างมีประสิทธิภาพ ขณะที่ BiLSTM ให้ผลลัพธ์อยู่ในระดับดีและมีประสิทธิภาพใกล้เคียงกับ Logistic Regression แต่ใช้เวลาในการประมวลผลสูงกว่า ส่วน Random Forest เป็นโมเดลที่ให้ผลลัพธ์ต่ำที่สุด โดยเฉพาะค่า Accuracy และ F1-score ที่ลดลงเมื่อเทียบกับโมเดลอื่น แสดงถึงข้อจำกัดในการจัดการข้อมูลข้อความที่มีบริบทซับซ้อน

4.4.2 การเปรียบเทียบ Hybrid Model ที่ใช้ Llama 3.1:8B

ตารางที่ 4.4-2 การเปรียบเทียบประสิทธิภาพของ Hybrid Model ที่ใช้ Llama 3.1:8B

โมเดล	Accuracy	F1-Macro	F1-Weighted	Total pipeline time
Naive Bayes + Llama 3.1:8B	0.8117	0.8175	0.8158	1m 32s
Logistic Regression + Llama 3.1:8B	0.7809	0.7883	0.7868	1m 32s
Random Forest + Llama 3.1:8B	0.7130	0.7229	0.7166	1m 32s
SVM + Llama 3.1:8B	0.8827	0.8840	0.8824	1m 32s
BiLSTM + Llama 3.1:8B	0.8673	0.8689	0.8658	1m 32s

จากผลการทดลองพบว่า Hybrid Model ที่ใช้ Llama 3.1:8B ไม่สามารถเพิ่มประสิทธิภาพของโมเดลได้ โดยโมเดลส่วนใหญ่มีค่า Accuracy และ F1-Macro ลดลงจาก baseline อย่างชัดเจน โดยเฉพาะ Logistic Regression และ Naive Bayes ซึ่งสะท้อนถึงผลกระทบจากการปรับแก้ผลลัพธ์ที่ไม่เหมาะสมของ LLM

4.4.3 การเปรียบเทียบ Hybrid Model ที่ใช้ DeepSeek-R1:8B

ตารางที่ 4.4-3 การเปรียบเทียบประสิทธิภาพของ Hybrid Model ที่ใช้ DeepSeek-R1:8B

โมเดล	Accuracy	F1-Macro	F1-Weighted	Total pipeline time
Naive Bayes + DeepSeek-R1:8B	0.9043	0.9095	0.9034	42m 43s
Logistic Regression + DeepSeek-R1:8B	0.8920	0.8962	0.8919	42m 43s
Random Forest + DeepSeek-R1:8B	0.8827	0.8887	0.8824	42m 43s
SVM + DeepSeek-R1:8B	0.9074	0.9160	0.9061	42m 43s
BiLSTM + DeepSeek-R1:8B	0.9074	0.9137	0.9056	42m 43s

จากผลการทดลองพบว่า DeepSeek-R1:8B สามารถช่วยเพิ่มประสิทธิภาพของโมเดลได้ โดยค่า Accuracy และ F1-Macro ของหลายโมเดลสูงขึ้นเมื่อเทียบกับ baseline โดยเฉพาะ SVM และ BiLSTM อย่างไรก็ตาม การประมวลผลใช้เวลาสูงมาก ซึ่งเป็นข้อจำกัดสำคัญในการใช้งานจริง

4.4.4 การเปรียบเทียบ Hybrid Model ที่ใช้ Qwen 2.5:7B-Instruct

ตารางที่ 4.4-4 การเปรียบเทียบประสิทธิภาพของ Hybrid Model ที่ใช้ Qwen 2.5:7B-Instruct

โมเดล	Accuracy	F1-Macro	F1-Weighted	Total pipeline time
Naive Bayes + Qwen 2.5:7B-Instruct	0.9105	0.9182	0.9091	1m 20s
Logistic Regression + Qwen 2.5:7B-Instruct	0.8981	0.9072	0.8975	1m 20s
Random Forest + Qwen 2.5:7B-Instruct	0.8889	0.8966	0.8880	1m 20s
SVM + Qwen 2.5:7B-Instruct	0.9167	0.9255	0.9154	1m 20s
BiLSTM + Qwen 2.5:7B-Instruct	0.9136	0.9203	0.9113	1m 20s

จากผลการทดลองพบว่า Qwen 2.5:7B-Instruct ให้ประสิทธิภาพดีที่สุดในกลุ่ม Hybrid Model โดยสามารถเพิ่มทั้ง Accuracy และ F1-Macro ได้อย่างสม่ำเสมอในทุกโมเดล และยังใช้เวลาในการประมวลผลน้อยกว่า DeepSeek อย่างชัดเจน ทำให้มีความเหมาะสมต่อการใช้งานจริงมากกว่า

4.4.5 การเปรียบเทียบโมเดลที่ดีที่สุดในแต่ละกลุ่ม

ตารางที่ 4.4-5 การเปรียบเทียบโมเดลที่มีประสิทธิภาพดีที่สุดในแต่ละกลุ่ม

Model	Type	Accuracy	F1-Macro	Time
SVM	ML	0.9136	0.9276	3.15 s
BiLSTM	DL	0.9043	0.9170	12.35 s
BiLSTM + Llama 3.1:8B	Hybrid (Llama 3.1:8B)	0.8673	0.8689	1m 32s
BiLSTM + DeepSeek-R1:8B	Hybrid (DeepSeek-R1:8B)	0.9074	0.9137	42m 43s
SVM + Qwen 2.5:7B-Instruct	Hybrid (Qwen 2.5:7B-Instruct)	0.9167	0.9255	1m 20s

จากผลการทดลองพบว่า SVM เป็นโมเดลที่มีประสิทธิภาพดีที่สุดในกลุ่ม Machine Learning และ BiLSTM ในกลุ่ม Deep Learning ขณะที่ Hybrid Model ที่ให้ผลลัพธ์ดีที่สุดคือ SVM + Qwen 2.5:7B-Instruct ซึ่งให้ทั้งความแม่นยำสูงและมีประสิทธิภาพด้านเวลาเหมาะสมที่สุด

4.4.6 สรุปผลการเปรียบเทียบ

จากผลการทดลองสามารถสรุปประเด็นสำคัญได้ดังนี้

- โมเดลพื้นฐานที่ให้ Accuracy สูงที่สุดคือ BiLSTM ขณะที่ Support Vector Machine (SVM) มีความสมดุลของผลลัพธ์ดีที่สุดในกลุ่ม Machine Learning
- การใช้ Llama 3.1:8B ในแนวทาง Hybrid ส่งผลให้ประสิทธิภาพของโมเดลลดลงในหลายกรณี สะท้อนถึงปัญหา over-correction จากการปรับแก้ผลลัพธ์
- DeepSeek-R1:8B สามารถเพิ่มความแม่นยำของโมเดลได้อย่างชัดเจน แต่มีข้อจำกัดด้านเวลาในการประมวลผลที่สูงมาก
- Qwen 2.5:7B-Instruct ให้ผลลัพธ์ที่ดีที่สุดในภาพรวม โดยมีทั้ง Accuracy และ F1-Macro สูง พร้อมทั้งใช้เวลาในการประมวลผลต่ำกว่า DeepSeek อย่างมีนัยสำคัญ
- โมเดล Hybrid ที่มีประสิทธิภาพสูงที่สุดคือ BiLSTM + Qwen 2.5:7B-Instruct และในกลุ่ม Machine Learning Hybrid คือ SVM + Qwen 2.5:7B-Instruct


โดยสรุป แนวทาง Hybrid Model ไม่ได้ให้ผลลัพธ์ดีขึ้นในทุกกรณี แต่ขึ้นอยู่กับ LLM ที่เลือกใช้ โดย Qwen 2.5:7B-Instruct เป็นตัวเลือกที่เหมาะสมที่สุดสำหรับการใช้งานจริง

4.5 Confusion Matrix

ในหัวข้อนี้เป็นการวิเคราะห์ผลการจำแนกของโมเดลในระดับรายคลาส โดยใช้ Confusion Matrix ซึ่งเป็นตารางที่แสดงความสัมพันธ์ระหว่างค่าจริง (True Label) และค่าที่โมเดลทำนาย (Predicted Label) เพื่อให้สามารถพิจารณาความถูกต้องและความผิดพลาดของโมเดลได้อย่างละเอียด

4.5.1 ผลการวิเคราะห์ Confusion Matrix ของโมเดล Machine Learning และ Deep Learning

1) Naive Bayes




รูปที่ 4.5-1 Confusion Matrix ของโมเดล Naive Bayes

จากรูปที่ 4.5-1 พบว่าโมเดลสามารถจำแนกคลาส angry (49), disgust (57), happy (34) และ sad (40) ได้อย่างแม่นยำสูง โดยค่าบนแนวทแยงมุมมีความเด่นชัด อย่างไรก็ตามพบความคลาดเคลื่อนในคลาส fear และ neutral ดังนี้

- fear ถูกทำนายเป็น neutral (11), disgust (4) และ sad (1)
- neutral ถูกทำนายเป็น fear (7) และ disgust (3)

สะท้อนว่าโมเดลมีข้อจำกัดในการแยกแยะอารมณ์ที่มีลักษณะใกล้เคียงกัน โดยเฉพาะระหว่าง fear และ neutral

2) Logistic Regression




รูปที่ 4.5-2 Confusion Matrix ของโมเดล Logistic Regression

จากรูปที่ 4.5-2 พบว่าโมเดลสามารถจำแนกคลาส angry (49), disgust (59), happy (34) และ sad (40) ได้อย่างแม่นยำสูง โดยค่าบนแนวทแยงมุมมีความชัดเจน อย่างไรก็ตามยังพบความคลาดเคลื่อนในบางคลาส ดังนี้

- fear ถูกทำนายเป็น neutral (8), disgust (3) และ sad (1)
- neutral ถูกทำนายเป็น fear (10) และ disgust (3)

แสดงให้เห็นว่าแม้โมเดลจะมีประสิทธิภาพโดยรวมที่ดี แต่ยังมีข้อจำกัดในการแยกแยะคลาสที่มีความกำกวม โดยเฉพาะ fear และ neutral

3) Random Forest




รูปที่ 4.5-3 Confusion Matrix ของโมเดล Random Forest

จากรูปที่ 4.5-3 พบว่าโมเดลสามารถจำแนกคลาส angry (49), happy (34), neutral (69) และ sad (39) ได้ดี อย่างไรก็ตามพบความคลาดเคลื่อนที่ชัดเจนในบางคลาส ดังนี้

- fear ถูกทำนายเป็น neutral (22) และ disgust (2)
- disgust ถูกทำนายเป็น neutral (14)
- neutral ถูกทำนายเป็น disgust (4), angry (1) และ sad (1)

สะท้อนว่าโมเดลมีแนวโน้มเอนเอียง (bias) ไปยังคลาส neutral ส่งผลให้หลายคลาสถูกทำนายเป็น neutral มากกว่าความเป็นจริง

4) Support Vector Machine (SVM)




รูปที่ 4.5-4 Confusion Matrix ของโมเดล Support Vector Machine (SVM)

จากรูปที่ 4.5-4 พบว่าโมเดลสามารถจำแนกคลาส angry (49), disgust (59), fear (50), happy (34), neutral (64) และ sad (40) ได้อย่างแม่นยำสูง โดยค่าบนแนวทแยงมุมมีความเด่นชัด ความคลาดเคลื่อนของโมเดลมีค่อนข้างน้อย ดังนี้

- fear ถูกทำนายเป็น neutral (6) และ disgust (4)
- neutral ถูกทำนายเป็น fear (7), disgust (3) และ sad (1)

สะท้อนว่า SVM เป็นโมเดลที่สามารถแยกแยะคลาสที่มีความกำกวมได้ดีที่สุดเมื่อเทียบกับโมเดลอื่นในกลุ่ม Machine Learning

5) Deep Learning (BiLSTM)



รูปที่ 4.5-5 Confusion Matrix ของโมเดล Deep Learning (BiLSTM)


จากรูปที่ 4.5-5 พบว่าโมเดล BiLSTM สามารถจำแนกคลาส angry (49), disgust (61), happy (34) และ sad (41) ได้อย่างแม่นยำสูง โดยค่าบนแนวทแยงมุมมีความเด่นชัด อย่างไรก็ตามยังพบความคลาดเคลื่อนในคลาส fear และ neutral ดังนี้

- fear ถูกทำนายเป็น neutral (13) และ disgust (3)
- neutral ถูกทำนายเป็น fear (5), angry (2), disgust (2) และ happy (2)

แม้ว่า neutral (64) จะมีจำนวนการทำนายถูกในระดับสูง แต่ยังคงเกิดความสับสนกับหลายคลาส สะท้อนถึงข้อจำกัดของโมเดลในการแยกแยะอารมณ์ที่มีลักษณะใกล้เคียงกัน โดยเฉพาะระหว่าง fear และ neutral

4.5.2 ผลการวิเคราะห์ Confusion Matrix ของโมเดลที่ใช้ Llama3.1:8b

1) ผลการวิเคราะห์ Confusion Matrix ของ Naive Bayes + Llama3.1:8b




รูปที่ 4.5-6 Confusion Matrix ของโมเดล Naive Bayes ร่วมกับ Llama3.1:8b

จากรูปที่ 4.5-6 พบว่าโมเดลสามารถจำแนกคลาส angry (49), happy (35) และ sad (41) ได้ในระดับดี อย่างไรก็ตาม พบความคลาดเคลื่อนในหลายคลาส ดังนี้

- disgust ถูกทำนายเป็น sad (11) และ angry (3)
- fear ถูกทำนายเป็น sad (12) และ neutral (2)
- neutral ถูกทำนายเป็น sad (14) และ happy (11)

สะท้อนว่าโมเดลมีแนวโน้มทำนายไปยังคลาส sad และ happy มากขึ้น ส่งผลให้ความสมดุลของการจำแนกแต่ละคลาสดลดลง

2) ผลการวิเคราะห์ Confusion Matrix ของ Logistic Regression + Llama3.1:8b




รูปที่ 4.5-7 Confusion Matrix ของโมเดล Logistic Regression ร่วมกับ Llama3.1:8b

จากรูปที่ 4.5-7 พบว่าโมเดลสามารถจำแนกคลาส happy (35) และ sad (41) ได้ดี อย่างไรก็ตาม พบความคลาดเคลื่อนที่ชัดเจนในหลายคลาส ดังนี้

- angry ถูกทำนายเป็น sad (5)
- disgust ถูกทำนายเป็น sad (13) และ angry (3)
- fear ถูกทำนายเป็น sad (9)
- neutral ถูกทำนายเป็น sad (17) และ happy (14)

แสดงให้เห็นว่าโมเดลมีแนวโน้ม bias ไปทางคลาส sad และ happy อย่างชัดเจน ส่งผลให้หลายคลาสถูกทำนายคลาดเคลื่อน

3) ผลการวิเคราะห์ Confusion Matrix ของ Random Forest + Llama3.1:8b




รูปที่ 4.5-8 Confusion Matrix ของโมเดล Random Forest ร่วมกับ Llama3.1:8b

จากรูปที่ 4.5-8 พบว่าโมเดลสามารถจำแนกคลาส angry (44), happy (35) และ sad (41) ได้ในระดับดี อย่างไรก็ตาม พบความคลาดเคลื่อนสูงในบางคลาส ดังนี้ disgust ถูกทำนายเป็น

- sad (16)
- fear ถูกทำนายเป็น sad (12) และ happy (4)
- neutral ถูกทำนายเป็น sad (26) และ happy (21)

แม้ว่า neutral จะมีจำนวนการทำนายถูกอยู่ในระดับหนึ่ง แต่มีการกระจายไปยังคลาสอื่นจำนวนมาก โดยเฉพาะ sad และ happy สะท้อนว่าโมเดลมีแนวโน้มเอนเอียงไปยังคลาส sad อย่างชัดเจน

4) ผลการวิเคราะห์ Confusion Matrix ของ SVM + Llama3.1:8b




รูปที่ 4.5-9 Confusion Matrix ของโมเดล Support Vector Machine ร่วมกับ Llama3.1:8b

จากรูปที่ 4.5-9 พบว่าโมเดล SVM ยังคงให้ผลลัพธ์ที่ดีที่สุดในกลุ่มที่ใช้ Llama โดยสามารถจำแนกคลาส angry (49), disgust (58), happy (35) และ sad (41) ได้อย่างแม่นยำ ความคลาดเคลื่อนที่พบได้แก่

- fear ถูกทำนายเป็น sad (7) และ neutral (3)
- neutral ถูกทำนายเป็น sad (8) และ happy (7)

แม้จะยังมีความคลาดเคลื่อนอยู่บ้าง แต่โมเดลยังคงรักษาความสมดุลในการจำแนกคลาสได้ดีกว่าโมเดลอื่นในกลุ่มเดียวกัน

5) ผลการวิเคราะห์ Confusion Matrix ของ Deep Learning BiLSTM + Llama3.1:8b



รูปที่ 4.5-10 Confusion Matrix ของโมเดล Deep Learning (BiLSTM) ร่วมกับ Llama 3.1:8b


จากรูปที่ 4.5-10 พบว่าโมเดลสามารถจำแนกคลาส angry (49), disgust (59), happy (35) และ sad (40) ได้ดี อย่างไรก็ตาม พบความคลาดเคลื่อนในคลาสที่มีความกำกวม ดังนี้

- fear ถูกทำนายเป็น neutral (6) และ sad (6)
- neutral ถูกทำนายเป็น sad (8) และ happy (6)

แม้ว่า neutral (56) จะมีจำนวนการทำนายถูกในระดับหนึ่ง แต่ยังคงเกิดความสับสนกับหลายคลาส โดยเฉพาะ sad สะท้อนถึงข้อจำกัดในการแยกแยะอารมณ์ที่มีลักษณะใกล้เคียงกัน

4.5.3 ผลการวิเคราะห์ Confusion Matrix ของโมเดลที่ใช้ DeepSeek-R1:8B

1) ผลการวิเคราะห์ Confusion Matrix ของ Naive Bayes + DeepSeek-R1:8B




รูปที่ 4.5-11 Confusion Matrix ของโมเดล Naive Bayes ร่วมกับ DeepSeek R1

จากรูปที่ 4.5-11 พบว่าโมเดลสามารถจำแนกคลาส angry (49), disgust (57), happy (35), neutral (65) และ sad (40) ได้ในระดับดี อย่างไรก็ตามยังพบความคลาดเคลื่อนในบางคลาส ดังนี้

- fear ถูกทำนายเป็น neutral (9)
- neutral ถูกทำนายเป็น happy (6) และ fear (3)
- disgust ถูกทำนายเป็น neutral (3), angry (2) และ sad (2)

สะท้อนว่าแม้โมเดลจะมีความแม่นยำโดยรวมดีขึ้น แต่ยังมีข้อจำกัดในการแยกแยะคลาสที่มีความกำกวม โดยเฉพาะ fear และ neutral

2) ผลการวิเคราะห์ Confusion Matrix ของ Logistic Regression + DeepSeek-R1:8B




รูปที่ 4.5-12 Confusion Matrix ของโมเดล Logistic Regression ร่วมกับ DeepSeek-R1:8B

จากรูปที่ 4.5-12 พบว่าโมเดลสามารถจำแนกคลาส happy (35), neutral (66) และ sad (41) ได้อย่างแม่นยำ อย่างไรก็ตามยังพบความคลาดเคลื่อนในบางคลาส ดังนี้

- fear ถูกทำนายเป็น neutral (13)
- neutral ถูกทำนายเป็น happy (5), fear (2) และ sad (2)
- angry ถูกทำนายเป็น sad (4)
- disgust ถูกทำนายเป็น sad (4) และ angry (3)

แสดงให้เห็นว่าแม้โมเดลจะมีประสิทธิภาพโดยรวมดีขึ้น แต่ยังคงมีความสับสนระหว่าง fear และ neutral อยู่บางกรณี

3) ผลการวิเคราะห์ Confusion Matrix ของ Random Forest + DeepSeek-R1:8B




รูปที่ 4.5-13 Confusion Matrix ของโมเดล Random Forest ร่วมกับ DeepSeek-R1:8B

จากรูปที่ 4.5-13 พบว่าโมเดลสามารถจำแนกคลาส angry (45), happy (35), neutral (67) และ sad (41) ได้ดี อย่างไรก็ตามยังพบความคลาดเคลื่อนในบางคลาส ดังนี้

- fear ถูกทำนายเป็น neutral (14)
- disgust ถูกทำนายเป็น sad (5), neutral (3), angry (2) และ fear (1)
- neutral ถูกทำนายเป็น happy (5) และ fear (2)

สะท้อนว่าคลาส fear ยังคงมีความท้าทายสูง และมีแนวโน้มถูกทำนายเป็น neutral มากกว่าคลาสอื่น

4) ผลการวิเคราะห์ Confusion Matrix ของ SVM + DeepSeek-R1:8B




รูปที่ 4.5-14 Confusion Matrix ของโมเดล Support Vector Machine ร่วมกับ DeepSeek-R1:8B

จากรูปที่ 4.5-14 พบว่าโมเดล SVM ให้ผลลัพธ์ที่ดีที่สุดในกลุ่ม DeepSeek โดยสามารถจำแนกคลาส angry (49), disgust (59), happy (35), neutral (65) และ sad (41) ได้อย่างแม่นยำ ความคลาดเคลื่อนที่พบ ได้แก่

- fear ถูกทำนายเป็น neutral (13), disgust (1) และ happy (1)
- neutral ถูกทำนายเป็น fear (4), happy (4) และ sad (2)
- disgust ถูกทำนายเป็น angry (3) และ neutral (2)

แม้จะยังมีความสับสนในคลาส fear และ neutral อยู่บ้าง แต่โดยรวมมีความคลาดเคลื่อนต่ำกว่าโมเดลอื่นในกลุ่มเดียวกัน

5) ผลการวิเคราะห์ Confusion Matrix ของ Deep Learning (BiLSTM)+ DeepSeek-R1:8B



รูปที่ 4.5-15 Confusion Matrix ของโมเดล Deep Learning (BiLSTM) ร่วมกับ DeepSeek-R1:8B


จากรูปที่ 4.5-15 พบว่าโมเดลสามารถจำแนกคลาส angry (49), disgust (59), happy (35), neutral (67) และ sad (40) ได้ดี อย่างไรก็ตามยังพบความคลาดเคลื่อนในบางคลาส ดังนี้

- fear ถูกทำนายเป็น neutral (12), happy (2) และ disgust (2)
- neutral ถูกทำนายเป็น happy (3), fear (2), sad (2) และ disgust (1)
- disgust ถูกทำนายเป็น fear (3)

สะท้อนว่าแม้โมเดลจะมีประสิทธิภาพโดยรวมดีขึ้น แต่ยังคงมีข้อจำกัดในการแยกแยะคลาสที่มีลักษณะใกล้เคียงกัน โดยเฉพาะ fear และ neutral

4.5.4 ผลการวิเคราะห์ Confusion Matrix ของโมเดลที่ใช้ Qwen 2.5:7B-Instruct

1) ผลการวิเคราะห์ Confusion Matrix ของ Naive Bayes + Qwen 2.5:7B-Instruct




รูปที่ 4.5-16 Confusion Matrix ของโมเดล Naive Bayes ร่วมกับ Qwen 2.5:7B-Instruct

จากรูปที่ 4.5-16 พบว่าโมเดลสามารถจำแนกคลาส angry (49), happy (35), neutral (68) และ sad (41) ได้ดี อย่างไรก็ตามยังพบความคลาดเคลื่อนในบางคลาส ดังนี้

- fear ถูกทำนายเป็น neutral (14) และ disgust (2)
- neutral ถูกทำนายเป็น happy (5) และ fear (2)
- disgust ถูกทำนายเป็น sad (3), neutral (2) และ angry (1)

สะท้อนว่าโมเดลยังมีข้อจำกัดในการแยกแยะคลาสที่มีลักษณะใกล้เคียงกัน โดยเฉพาะ fear และ neutral

2) ผลการวิเคราะห์ Confusion Matrix ของ Logistic Regression + Qwen 2.5:7B-Instruct



รูปที่ 4.5-17 Confusion Matrix ของโมเดล Logistic Regression ร่วมกับ Qwen 2.5:7B-Instruct


จากรูปที่ 4.5-17 พบว่าโมเดลสามารถจำแนกคลาส happy (35), neutral (68) และ sad (41)

ได้อย่างแม่นยำ อย่างไรก็ตามยังพบความคลาดเคลื่อนในบางคลาส ดังนี้

- fear ถูกทำนายเป็น neutral (14) และ disgust (2)
- angry ถูกทำนายเป็น neutral (3)
- disgust ถูกทำนายเป็น sad (3), angry (2) และ neutral (2)
- neutral ถูกทำนายเป็น happy (5) และ fear (2)

แสดงให้เห็นว่าแม้โมเดลจะมีความแม่นยำโดยรวมดี แต่ยังคงมีความสับสนในคลาส fear และ neutral อยู่บางส่วน

3) ผลการวิเคราะห์ Confusion Matrix ของ Random Forest + Qwen 2.5:7B-Instruct



รูปที่ 4.5-18 Confusion Matrix ของโมเดล Random Forest ร่วมกับ Qwen 2.5:7B-Instruct


จากรูปที่ 4.5-18 พบว่าโมเดลสามารถจำแนกคลาส angry (46), happy (35), neutral (69) และ sad (41) ได้ดี อย่างไรก็ตามยังพบความคลาดเคลื่อนในบางคลาส ดังนี้

- fear ถูกทำนายเป็น neutral (14), disgust (2) และ sad (1)
- disgust ถูกทำนายเป็น sad (5), neutral (3) และ angry (2)
- neutral ถูกทำนายเป็น happy (5) และ sad (1)

สะท้อนว่าคลาส fear ยังคงมีความท้าทายสูง และมีแนวโน้มถูกทำนายเป็น neutral มากกว่าคลาส

อื่น

4) ผลการวิเคราะห์ Confusion Matrix ของ SVM + Qwen 2.5:7B-Instruct




รูปที่ 4.5-19 Confusion Matrix ของโมเดล Support Vector Machine ร่วมกับ Qwen 2.5:7B-Instruct

จากรูปที่ 4.5-19 พบว่าโมเดล SVM ให้ผลลัพธ์ที่ดีที่สุดในกลุ่มนี้ โดยสามารถจำแนกคลาส angry (49), disgust (59), happy (35), neutral (68) และ sad (41) ได้อย่างแม่นยำ ความคลาดเคลื่อนที่พบได้แก่

- fear ถูกทำนายเป็น neutral (13) และ disgust (2)
- neutral ถูกทำนายเป็น fear (3), happy (3) และ sad (1)
- disgust ถูกทำนายเป็น angry (2) และ neutral (2)

แม้จะยังมีความสับสนในบางคลาส แต่โดยรวมมีความคลาดเคลื่อนต่ำและมีความสมดุลในการจำแนกที่ดีที่สุดในกลุ่มโมเดลที่ใช้ Qwen

5) ผลการวิเคราะห์ Confusion Matrix ของ Deep Learning (BiLSTM)+ Qwen 2.5:7B-Instruct



รูปที่ 4.5-20 Confusion Matrix ของโมเดล Deep Learning (BiLSTM) ร่วมกับ DeepSeek-R1:8B

จากรูปที่ 4.5-20 พบว่าโมเดลสามารถจำแนกคลาส angry (49), disgust (60), happy (35), neutral (69) และ sad (40) ได้ดี อย่างไรก็ตามยังพบความคลาดเคลื่อนในบางคลาส ดังนี้

- fear ถูกทำนายเป็น neutral (13), disgust (3) และ happy (1)
- neutral ถูกทำนายเป็น happy (3), fear (2) และ disgust (1)
- disgust ถูกทำนายเป็น fear (1) และ sad (1)
- sad ถูกทำนายเป็น fear (1)

สะท้อนว่าแม้โมเดลจะมีประสิทธิภาพโดยรวมดีขึ้น แต่ยังคงมีข้อจำกัดในการแยกแยะคลาสที่มีลักษณะใกล้เคียงกัน โดยเฉพาะ fear และ neutral

4.5.5 สรุปผล Confusion Matrix ของโมเดลทั้งหมด

จากการวิเคราะห์ Confusion Matrix พบว่า โมเดลทุกแบบสามารถจำแนกคลาสที่มีลักษณะชัดเจน ได้แก่ angry, happy และ sad ได้ดี ในขณะที่คลาส fear และ neutral มีความกำกวมสูง ส่งผลให้เกิดความคลาดเคลื่อนอย่างต่อเนื่อง โดยเฉพาะการสับสนระหว่างสองคลาสนี้

สำหรับกลุ่ม Machine Learning และ Deep Learning (Baseline) พบว่า SVM ให้ผลลัพธ์ที่ดีที่สุด เนื่องจากมีความคลาดเคลื่อนต่ำและมีความสมดุลในการจำแนก ขณะที่ Random Forest มีแนวโน้มเอนเอียงไปยังคลาส neutral

ในกลุ่ม Hybrid Model ประสิทธิภาพขึ้นอยู่กับ LLM ที่ใช้ โดย

- Llama 3.1:8B เพิ่มความคลาดเคลื่อนและเกิด bias ไปที่ sad และ happy
- DeepSeek-R1:8B ช่วยให้ผลลัพธ์สมดุลมากขึ้น แต่ยังสับสนใน fear และ neutral
- Qwen 2.5:7B-Instruct ให้ผลลัพธ์ที่ดีที่สุด โดยลดความคลาดเคลื่อนของคลาสกำกวมได้ชัดเจน

สรุป: ปัญหาหลักอยู่ที่คลาส fear และ neutral และการใช้ Hybrid Model สามารถช่วยปรับปรุงผลลัพธ์ได้ โดย Qwen 2.5:7B-Instruct ให้ประสิทธิภาพดีที่สุดโดยรวม

บทที่ 5

สรุปผลและข้อเสนอแนะ

5.1 สรุปผลโครงการ

โครงการนี้มีวัตถุประสงค์เพื่อพัฒนาระบบวิเคราะห์อารมณ์จากข้อความสนทนาในบริบททางทันตกรรม โดยประยุกต์ใช้เทคนิค Machine Learning และ Deep Learning เป็นโมเดลหลักในการจำแนกอารมณ์ และนำ Large Language Model (LLM) มาใช้ในลักษณะ Hybrid เพื่อช่วยปรับปรุงผลลัพธ์ในกรณีที่ข้อความมีความกำกวมหรือซับซ้อน จากผลการทดลองพบว่า โมเดล Machine Learning โดยเฉพาะ Support Vector Machine (SVM) ให้ประสิทธิภาพดีที่สุดในกลุ่มโมเดลพื้นฐาน โดยมีค่า Accuracy และ F1-score สูงที่สุด สะท้อนถึงความสามารถในการจัดการข้อมูลข้อความที่มีมิติสูงได้อย่างมีประสิทธิภาพ ขณะที่โมเดล Deep Learning อย่าง BiLSTM ให้ผลลัพธ์ใกล้เคียงกัน แต่มีต้นทุนด้านเวลาในการประมวลผลสูงกว่าอย่างชัดเจน

ในส่วนของแนวทาง Hybrid Model พบว่าประสิทธิภาพของระบบขึ้นอยู่กับ LLM ที่เลือกใช้ อย่างมีนัยสำคัญ โดย Llama 3.1 ไม่สามารถช่วยปรับปรุงผลลัพธ์ได้ และในหลายกรณีกลับทำให้ประสิทธิภาพลดลง เนื่องจากมีพฤติกรรมการปรับแก้ผลลัพธ์มากเกินไป (over-correction) ส่งผลให้ค่าที่ทำนายถูกต้องถูกแก้ไขเป็นค่าที่ผิด ในขณะที่ DeepSeek-R1 สามารถช่วยเพิ่มความแม่นยำของโมเดลได้ โดยเฉพาะในกรณีที่ข้อมูลมีความกำกวม เช่น คลาส fear และ neutral ซึ่งเป็นคลาสที่โมเดลพื้นฐานมักเกิดความสับสน อย่างไรก็ตาม การใช้งาน DeepSeek-R1 ยังคงมีข้อจำกัดด้านเวลาในการประมวลผลที่ค่อนข้างสูง

เมื่อพิจารณาภาพรวมของทุกโมเดล พบว่า Qwen 2.5 เป็นโมเดลที่ให้ประสิทธิภาพดีที่สุดในแนวทาง Hybrid โดยสามารถเพิ่มความแม่นยำของโมเดลได้อย่างสม่ำเสมอ และสามารถจัดการกับข้อความที่มีความกำกวมได้ดี โดยเฉพาะในคลาส neutral ซึ่งมีความซับซ้อนในการตีความ ส่งผลให้ค่าความถูกต้องโดยรวมสูงขึ้นอย่างมีนัยสำคัญ ดังนั้น แนวทาง Hybrid ที่ใช้ SVM ร่วมกับ Qwen 2.5 จึงถือเป็นแนวทางที่เหมาะสมที่สุดสำหรับการนำไปประยุกต์ใช้งานจริง เนื่องจากสามารถสร้างสมดุลระหว่างความแม่นยำและประสิทธิภาพด้านเวลาในการประมวลผลได้อย่างเหมาะสม

5.2 ปัญหาที่พบ

ในการดำเนินโครงการพบข้อจำกัดและปัญหาหลายประการ ซึ่งส่งผลกระทบต่อประสิทธิภาพของระบบ ดังนี้

1) ปัญหาความกำกวมของข้อมูล (Ambiguity in Text)

ข้อความในบริบทการสนทนามักมีลักษณะไม่ชัดเจน โดยเฉพาะอารมณ์ประเภท neutral และ fear ทำให้โมเดลเกิดความสับสนในการจำแนก

2) ปัญหาความไม่สมดุลของข้อมูล (Class Imbalance)

คลาส neutral มีจำนวนมากกว่าคลาสอื่นอย่างมีนัยสำคัญ ส่งผลให้โมเดลมีแนวโน้มทำนายไปยังคลาสนี้มากเกินไป

3) ข้อจำกัดของ Machine Learning

โมเดล Machine Learning ไม่สามารถเข้าใจบริบทเชิงลึกของภาษาได้ดีพอ ทำให้เกิดความผิดพลาดในข้อความที่มีความซับซ้อน

4) ข้อจำกัดของ LLM บางโมเดล

LLM เช่น Llama 3.1 มีพฤติกรรมการแก้ผลลัพธ์มากเกินไป (over-correction) ส่งผลให้ผลลัพธ์ที่ถูกต้องถูกแก้ไขเป็นผิด

5) ปัญหาด้านเวลาในการประมวลผล

การใช้ LLM โดยเฉพาะ DeepSeek-R1 มีต้นทุนด้านเวลาในการประมวลผลสูง ทำให้ไม่เหมาะกับการใช้งานในระบบที่ต้องการความรวดเร็ว

6) การกำหนดค่า Threshold ของ Hybrid Model

การกำหนดค่า confidence threshold มีผลกระทบต่อประสิทธิภาพของระบบ หากตั้งค่าไม่เหมาะสม อาจทำให้เรียกใช้ LLM มากเกินไปหรือไม่เพียงพอ

5.3 ข้อเสนอแนะ

จากผลการศึกษาและปัญหาที่พบ สามารถเสนอแนวทางในการพัฒนาเพิ่มเติมในอนาคตได้ดังนี้

1) การปรับปรุงคุณภาพและปริมาณข้อมูล

ควรเพิ่มจำนวนข้อมูลในแต่ละคลาสให้มีความสมดุลมากยิ่งขึ้น โดยเฉพาะคลาสที่มีข้อมูลน้อยหรือมีความกำกวม เช่น *fear* และ *neutral* รวมถึงการปรับปรุงคุณภาพของข้อมูลให้มีความชัดเจนและสอดคล้องกับบริบทจริง จะช่วยให้โมเดลสามารถเรียนรู้ลักษณะของข้อมูลได้อย่างมีประสิทธิภาพมากขึ้น

2) การพัฒนาโมเดล Hybrid ให้มีความยืดหยุ่นมากขึ้น

ควรปรับปรุงกลไกการตัดสินใจของระบบ Hybrid เช่น การใช้ค่า threshold แบบปรับเปลี่ยนได้ (dynamic threshold) หรือการใช้วิธี ensemble decision เพื่อลดความผิดพลาดและเพิ่มความแม่นยำในการจำแนกข้อมูล โดยเฉพาะในกรณีที่ข้อความมีความกำกวมสูง

3) การทดลองใช้ LLM ที่มีประสิทธิภาพสูงขึ้น

ควรศึกษาการนำโมเดล LLM รุ่นที่มีขนาดใหญ่ขึ้น หรือโมเดลที่ผ่านการ fine-tune เฉพาะด้าน (domain-specific) มาใช้งาน เพื่อเพิ่มความสามารถในการเข้าใจบริบทของภาษา โดยเฉพาะในบริบททางการแพทย์หรือทันตกรรม ซึ่งมีลักษณะเฉพาะทาง

4) การปรับปรุง Prompt Engineering

การออกแบบ prompt ให้มีความเหมาะสมและสอดคล้องกับลักษณะของข้อมูล จะช่วยให้ LLM สามารถให้ผลลัพธ์ที่แม่นยำและมีความสม่ำเสมอมากยิ่งขึ้น โดยอาจมีการทดลองใช้รูปแบบ prompt ที่หลากหลาย เช่น few-shot learning หรือ structured prompt

5) การลดต้นทุนด้านเวลาในการประมวลผล

ควรพัฒนาแนวทางที่ช่วยลดการเรียกใช้ LLM โดยไม่จำเป็น เช่น การปรับค่า threshold ให้เหมาะสม หรือการใช้เทคนิค caching สำหรับข้อความที่เคยประมวลผลแล้ว เพื่อลดระยะเวลาในการทำงานของระบบ และเพิ่มประสิทธิภาพในการใช้งานจริง

6) การต่อยอดสู่การใช้งานจริงและการรองรับข้อมูลเสียง

ในอนาคตสามารถนำระบบไปพัฒนาเป็นเครื่องมือช่วยวิเคราะห์อารมณ์ของผู้ป่วยในสถานการณ์จริง เพื่อสนับสนุนการสื่อสารระหว่างทันตแพทย์กับผู้ป่วย โดยอาจต่อยอดระบบให้รองรับข้อมูลเสียง (Speech-based Analysis) เช่น การแปลงเสียงเป็นข้อความ (Speech-to-Text) และนำมาวิเคราะห์อารมณ์ร่วมกับข้อมูลข้อความ รวมถึงการพิจารณาใช้ข้อมูลน้ำเสียง (tone) และจังหวะการพูด (prosody) เพื่อเพิ่มความแม่นยำในการวิเคราะห์อารมณ์ให้ครอบคลุมมากยิ่งขึ้น

บรรณานุกรม

- (1) Analytics Vidhya. (2021). Distinguish between tree-based machine learning algorithms. <https://www.analyticsvidhya.com/blog/2021/04/distinguish-between-tree-based-machine-learning-algorithms/>
- (2) Ashbaugh, M., & Zhang, X. (2024). Comparative analysis of machine learning and deep learning for sentiment analysis. *Journal of Artificial Intelligence Research*, 12(2), 45–62.
- (3) Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>
- (4) Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., Agarwal, S., Herbert-Voss, A., Krueger, G., Henighan, T., Child, R., Ramesh, A., Ziegler, D. M., Wu, J., Winter, C., & Amodei, D. (2020). Language models are few-shot learners. *Advances in Neural Information Processing Systems*, 33, 1877–1901.
- (5) Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16, 321–357. <https://doi.org/10.1613/jair.953>
- (6) Chulalongkorn University. (n.d.). Digital collection article. <https://digital.car.chula.ac.th/cgi/viewcontent>
- (7) Cornell University. (n.d.). Sentiment classification using machine learning techniques. <https://www.cs.cornell.edu/home/llee/papers/sentiment.pdf>
- (8) Cortes, C., & Vapnik, V. (1995). Support-vector networks. *Machine Learning*, 20(3), 273–297. <https://doi.org/10.1007/BF00994018>
- (9) DataCamp. (n.d.). Supervised machine learning. <https://www.datacamp.com/blog/supervised-machine-learning>

- (10)Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. Proceedings of NAACL-HLT 2019, 4171–4186. <https://doi.org/10.18653/v1/N19-1423>
- (11)Dietterich, T. G. (2000). Ensemble methods in machine learning. Lecture Notes in Computer Science, 1857, 1–15. https://doi.org/10.1007/3-540-45014-9_1
- (12)Ezen-Can, A. (2020). A comparison of LSTM and BERT for small corpus. arXiv Preprint arXiv:2009.05451. <https://arxiv.org/abs/2009.05451>
- (13)GeeksforGeeks. (n.d.). Top machine learning algorithms for classification. <https://www.geeksforgeeks.org/machine-learning/top-machine-learning-algorithms-for-classification/>
- (14)Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep learning. MIT Press.
- (15)Hastie, T., Tibshirani, R., & Friedman, J. (2009). The elements of statistical learning (2nd ed.). Springer. <https://doi.org/10.1007/978-0-387-84858-7>
- (16)Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. Neural Computation, 9(8), 1735–1780. <https://doi.org/10.1162/neco.1997.9.8.1735>
- (17)IBM. (n.d.). Support vector machine. IBM. <https://www.ibm.com/think/topics/support-vector-machine>
- (18)Kim, Y. (2014). Convolutional neural networks for sentence classification. Proceedings of EMNLP 2014, 1746–1751. <https://doi.org/10.3115/v1/D14-1181>
- (19)Kohavi, R. (1995). A study of cross-validation and bootstrap for accuracy estimation and model selection. Proceedings of the 14th International Joint Conference on Artificial Intelligence, 2, 1137–1143.
- (20)Machine Learning Mastery. (n.d.). Logistic vs SVM vs Random Forest: Which one wins for small datasets? <https://machinelearningmastery.com/logistic-vs-svm-vs-random-forest-which-one-wins-for-small-datasets/>

- (21)Manning, C. D., Raghavan, P., & Schütze, H. (2008). Introduction to information retrieval. Cambridge University Press. <https://doi.org/10.1017/CBO9780511809071>
- (22)McCallum, A., & Nigam, K. (1998). A comparison of event models for Naive Bayes text classification. Proceedings of the AAAI-98 Workshop on Learning for Text Categorization, 41–48.
- (23)MDPI. (2024). Computers, 13(12), 340. <https://www.mdpi.com/2073-431X/13/12/340>
- (24)Medium. (n.d.). TinyML multinomial Naive Bayes text classifier. <https://medium.com/@thommaskevin/tinyml-multinomial-naive-bayes-text-classifier-d5df9bccbd32>
- (25)Mitchell, T. M. (1997). Machine learning. McGraw-Hill.
- (26)Ollama. (n.d.). Ollama library. <https://ollama.com/library>
- (27)Pang, B., Lee, L., & Vaithyanathan, S. (2002). Thumbs up? Sentiment classification using machine learning techniques. Proceedings of EMNLP 2002, 79–86. <https://doi.org/10.3115/1118693.1118704>
- (28)Platt, J. C. (1999). Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods. Advances in Large Margin Classifiers, 10(3), 61–74.
- (29)ResearchGate. (2024). Sentiment analysis using machine learning: A comparative study. https://www.researchgate.net/publication/378985297_Sentiment_Analysis_Using_Machine_Learning_A_Comparative_Study
- (30)Salton, G., & Buckley, C. (1988). Term-weighting approaches in automatic text retrieval. Information Processing & Management, 24(5), 513–523. [https://doi.org/10.1016/0306-4573\(88\)90021-0](https://doi.org/10.1016/0306-4573(88)90021-0)
- (31)Sanfoundry. (n.d.). Classification algorithms: Decision trees, random forest, SVM, KNN, Naive Bayes. <https://www.sanfoundry.com/classification-algorithms-decision-trees-random-forest-svm-knn-naive-bayes/>

- (32)Schuster, M., & Paliwal, K. K. (1997). Bidirectional recurrent neural networks. IEEE Transactions on Signal Processing, 45(11), 2673–2681. <https://doi.org/10.1109/78.650093>
- (33)ScienceDirect. (2013). Expert Systems with Applications. <https://www.sciencedirect.com/science/article/abs/pii/S0957417412009153>
- (34)ScienceDirect. (2025). Healthcare analytics and sentiment classification research. <https://www.sciencedirect.com/org/science/article/pii/S1546221825007234>
- (35)Singh, A., & Jaiswal, U. C. (2023). Emotion detection from text using machine learning approach. International Journal of Advanced Computer Science and Applications, 14(3), 512–520.
- (36)Sokolova, M., & Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. Information Processing & Management, 45(4), 427–437. <https://doi.org/10.1016/j.ipm.2009.03.002>
- (37)Stack Exchange. (n.d.). Question about Platt scaling in scikit-learn’s implementation of SVM. Cross Validated. <https://stats.stackexchange.com/questions/620349/question-about-platt-scaling-in-sklearns-implementation-of-svm>
- (38)Unstop. (n.d.). Classification models in machine learning. <https://unstop.com/blog/classification-models-in-machine-learning>
- (39)Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. Advances in Neural Information Processing Systems, 30, 5998–6008.
- (40)Wikipedia contributors. (n.d.). Platt scaling. Wikipedia. https://en.wikipedia.org/wiki/Platt_scaling
- (41)Xiang, F., Wei, Y., Pan, X., Qiu, L., & Ma, Y. (2020). A framework for student review sentiment analysis and academic emotion classification. IEEE Access, 8, 108766–108776. <https://doi.org/10.1109/ACCESS.2020.3001629>

Source Code

https://github.com/Grace6687003/Senior_Project_Text_Mining.git